

Když prediktor není číslo

Od rozdílu průměrů k analýze rozptylu

28. září 2026

Obsah

1	Liší se průměrná hmotnost těla mezi druhy tučňáků?	2
2	Co se v této lekci naučíme	2
3	Data: jeden řádek je jeden změřený tučňák	2
4	Dva druhy: začneme jednotlivými pozorováními	6
4.1	Přidáme průměry	8
5	Rozdíl průměrů	9
5.1	Stejný rozdíl, jiná variabilita	10
6	Stejný lineární model, jiný prediktor	11
6.1	Opakování	11
6.2	Začneme daty a přímkou	12
6.3	Kde je intercept?	13
6.4	Kde je sklon?	14
6.5	Kde je residuum?	15
6.6	Fitujeme připomenutý model v R	16
7	Lineární model s kategoriální proměnnou	16
7.1	Odvození rovnice	18
8	Fitujeme dvouskupinový model v R	20
9	Odhadnuté hodnoty a residua nezmizely	23
10	Jak velký a přesný je rozdíl dvou druhů?	26
10.1	Testujeme nulový rozdíl	28
10.2	Historická poznámka: dvouvýběrový t-test v literatuře	30
11	Přidáme třetí druh, ale formule v R zůstane stejná	33
11.1	Tři skupiny potřebují dva přepínače	34
12	Jedna celková otázka: analýza rozptylu	35
12.1	Jeden společný průměr proti třem skupinovým průměrům	35
12.2	Co porovnává F-statistika	37
12.3	Jak číst tabulku <code>anova()</code> řádek po řádku	39
12.4	Jak se z F-statistiky stane p-hodnota	39
13	Post-hoc: které dvojice se liší?	40
14	Popisuje model data rozumně?	44
15	Co jednoduchý model neoddělil	46
16	Co tedy můžeme říct o tučňácích?	47

17 Propojení s celým dosavadním kurzem	48
18 Co si odnést	49
Slovníček pojmů	49

1 Liší se průměrná hmotnost těla mezi druhy tučňáků?

V předchozí lekci jsme se naučili převést biologické tvrzení na nulovou hypotézu a otestovat ji pomocí koeficientu známého modelu. Prediktorem byla spojitá proměnná a otázka zněla, zda je sklon slučitelný s nulou. Dnes použijeme stejný postup, ale prediktorem nebude měření: bude jím kategoriální proměnná (druh tučňáka).

Způsob uvažování se nezmění. Nejdříve se podíváme na jednotlivá pozorování, potom vyjádříme rozdíl (v gramech), přidáme nejistotu odhadu a teprve nakonec položíme testovou otázku.


2 Co se v této lekci naučíme

Po prostudování této lekce dokážete:

- fitovat `lm(y ~ skupina)` pro dvě i více skupin;
- vysvětlit, jak se obecný zápis lineárního modelu změní, když je prediktorem druh organismu;
- interpretovat intercept jako průměr referenční skupiny a ostatní koeficienty jako rozdíly vůči této skupině;
- vysvětlit dvouskupinový t-test a analýzu rozptylu jako případy lineárního modelu;
- rozlišit celkový test všech skupin od navazujících porovnání konkrétních dvojic a napsat závěr v biologicky smysluplných jednotkách.

3 Data: jeden řádek je jeden změřený tučňák

Data obsahují tělesná měření dospělých tučňáků tří druhů z Palmerova souostroví v Antarktidě. Jeden řádek představuje jednoho změřeného jedince. Naše odezva je hmotnost těla v gramech a kategoriálním prediktorem je druh.



Obrázek 1: Druhy tučňáků v datasetu Palmer Penguins a barvy, které pro ně budeme používat.
Ilustrace: Allison Horst.

Stejně jako v lekci o grafech a typech proměnných budeme tučňáka kroužkového (Adélie) zobrazovat oranžově, tučňáka uzdičkového (Chinstrap) fialově a tučňáka oslího (Gentoo) modrozeleně. Tabulku načteme a dvěma známými funkcemi zjistíme, jaké hodnoty a datové typy obsahuje. `summary()` ukáže základní souhrny sloupců a počty chybějících hodnot; `str()` ukáže strukturu tabulky a typ každé proměnné.

```
# Načteme připravenou tabulku s jedním řádkem na tučňáka
data_tucnaci <-
  read.csv(
    file = here::here("data", "palmer_penguins.csv"),
    na.strings = "NA"
  )

# Prohlédneme si souhrny hodnot
summary(data_tucnaci)
```

druh	ostrov	delka_zobaku_mm	hloubka_zobaku_mm
Length:344	Length:344	Min. :32.10	Min. :13.10
Class :character	Class :character	1st Qu.:39.23	1st Qu.:15.60
Mode :character	Mode :character	Median :44.45	Median :17.30
		Mean :43.92	Mean :17.15
		3rd Qu.:48.50	3rd Qu.:18.70
		Max. :59.60	Max. :21.50
		NA's :2	NA's :2

```
delka_kridla_mm hmotnost_tela_g  pohlavi      rok
Min.   :172.0   Min.   :2700   Length:344   Min.   :2007
1st Qu.:190.0   1st Qu.:3550   Class :character 1st Qu.:2007
Median :197.0   Median :4050   Mode  :character Median :2008
Mean   :200.9   Mean   :4202                      Mean   :2008
3rd Qu.:213.0   3rd Qu.:4750                      3rd Qu.:2009
Max.   :231.0   Max.   :6300                      Max.   :2009
NA's   :2       NA's   :2
```

```
# Zkontrolujeme strukturu a datové typy
str(data_tucnaci)
```

```
'data.frame':  344 obs. of  8 variables:
 $ druh          : chr  "Adelie" "Adelie" "Adelie" "Adelie" ...
 $ ostrov        : chr  "Torgersen" "Torgersen" "Torgersen" "Torgersen" ...
 $ delka_zobaku_mm : num  39.1 39.5 40.3 NA 36.7 39.3 38.9 39.2 34.1 42 ...
 $ hloubka_zobaku_mm: num  18.7 17.4 18 NA 19.3 20.6 17.8 19.6 18.1 20.2 ...
 $ delka_kridla_mm : int  181 186 195 NA 193 190 181 195 193 190 ...
 $ hmotnost_tela_g : int  3750 3800 3250 NA 3450 3650 3625 4675 3475 4250 ...
 $ pohlavi       : chr  "male" "female" "female" NA ...
 $ rok           : int  2007 2007 2007 2007 2007 2007 2007 2007 2007 2007 ...
```

Druh	Ostrov	Hmotnost těla (g)	Pohlaví	Rok
Adelie	Torgersen	3750	male	2007
Adelie	Torgersen	3800	female	2007
Adelie	Torgersen	3250	female	2007
Adelie	Torgersen	NA	NA	2007
Adelie	Torgersen	3450	female	2007
Adelie	Torgersen	3650	male	2007

Doplňující: získání a příprava dat

Pro průchod lekcí stačí připravený soubor `data/palmer_penguins.csv`. Ten záměrně zachovává všech 344 řádků, aby byly chybějící hodnoty při prvním prohlédnutí viditelné. Pokud si ale chcete celý postup zopakovat, následující kód provede celý sled kroků: **získá data** → **vybere a přejmenuje sloupce** → **připraví je pro model hmotnosti** → **uloží vlastní pracovní kopii**.

Původní tabulka má 2 chybějící hmotnosti. Lineární model hmotnosti z těchto řádků nemůže vypočítat residuum, protože nezná odezvu. Po načtení proto ponecháme 342 úplných pozorování s naměřenou hmotností a při přejmenování sloupců vytvoříme z druhu faktor s výslovně zadaným pořadím úrovní. Tento blok můžete přeskočit; další příklady používají připravený soubor načtený výše.

```
# Tento příkaz stačí spustit pouze jednou
# install.packages("palmerpenguins")

# Získáme data a prohlédneme chybějící hmotnosti
data_puvodni <- palmerpenguins::penguins
sum(is.na(data_puvodni$body_mass_g))
data_puvodni <- data_puvodni[!is.na(data_puvodni$body_mass_g), ]

# Vybereme, přejmenujeme a upravíme sloupce pro lekci
data_tucnaci <-
  data.frame(
    druh = factor(data_puvodni$species,
      levels = c("Adelie", "Chinstrap", "Gentoo")
    ),
    ostrov = as.character(data_puvodni$island),
    delka_zobaku_mm = data_puvodni$bill_length_mm,
    hloubka_zobaku_mm = data_puvodni$bill_depth_mm,
    delka_kridla_mm = data_puvodni$flipper_length_mm,
    hmotnost_tela_g = data_puvodni$body_mass_g,
    pohlavi = as.character(data_puvodni$sex),
    rok = data_puvodni$year
  )


# Uložíme si zpracovanou tabulku pro další práci
write.csv(
  x = data_tucnaci,
  file = here::here("data", "palmer_penguins_vlastni_kopie.csv"),
  row.names = FALSE,
```

```
na = ""  
)
```

R Balíček obsahuje kopii původních tabulek z Environmental Data Initiative. [Dokumentace balíčku palmerpenguins](#) uvádí také cestu k neupraveným archivním souborům. Měření pocházejí z výzkumu tučňáků rodu *Pygoscelis* v letech 2007–2009. Data shromáždila Kristen Gorman ve spolupráci s Palmer Station Long Term Ecological Research a byla zveřejněna pod licencí CC0. Připravený soubor a jeho přesná provenance jsou popsány v [data/README.md](#); biologickou studii uvádějí Gorman, Williams a Fraser (2014), DOI: [10.1371/journal.pone.0090081](#).

4 Dva druhy: začneme jednotlivými pozorováními

Začneme jen tučňákem kroužkovým a tučňákem oslím. V prvním grafu jsou všechny hmotnosti smíchané dohromady. Každý bod stále představuje jednoho jedince.



Obrázek 2: Hmotnosti tučňáků dvou druhů předtím, než použijeme informaci o druhu. Všechny body jsou záměrně šedé.

Bez další proměnné umíme popsat jen tento společný soubor. V lekci o popisu jedné proměnné jsme k tomu používali počet pozorování, minimum, maximum, průměr, medián a mezikvartilové rozpětí (IQR). Stejně souhrny nyní spočítáme v R:

```
# Pro první pohled vybereme dva druhy, ale zatím je nesrovnáváme  
data_dva_druhy <-
```

```
data_tucnaci[
  data_tucnaci$druh %in% c("Adelie", "Gentoo"),
]
data_dva_druhy$druh <- droplevels(data_dva_druhy$druh)

# Připomeneme si známé souhrny pro všechny hmotnosti dohromady
c(
  pocet = length(data_dva_druhy$hmotnost_tela_g),
  prumer = mean(data_dva_druhy$hmotnost_tela_g),
  median = median(data_dva_druhy$hmotnost_tela_g),
  minimum = min(data_dva_druhy$hmotnost_tela_g),
  maximum = max(data_dva_druhy$hmotnost_tela_g),
  IQR = IQR(data_dva_druhy$hmotnost_tela_g)
)
```

pocet	prumer	median	minimum	maximum	IQR
274.000	4318.066	4262.500	2850.000	6300.000	1350.000

Společný průměr 4318.1 g shrnuje střed šedého oblaku, ale zakrývá možnost, že se v něm mísí odlišné skupiny. Teď proto přidáme novou proměnnou `druh`.

Proměnná `druh` je kategoriální: její hodnoty nejsou měření na číselné škále, ale názvy kategorií. Funkce `table()` ukáže, kolik řádků (jedinců) patří do každé kategorie:


```
table(data_tucnaci$druh)
```

Adelie	Chinstrap	Gentoo
151	68	123

V celé tabulce jsou tři druhy. Pro první model zatím ponecháváme pouze Adélie a Gentoo, které jsme vybrali do objektu `data_dva_druhy`.

Než druhy barevně oddělíme

V předchozí lekci o testování hypotéz jsme se naučili testovat nulovou hypotézu o koeficientu modelu. Zkuste nyní vyslovit nulovou hypotézu pro průměrnou hmotnost Adélie a Gentoo. Až potom předpovězte: budou s ní podle barevného grafu data slučitelná?




Obrázek 3: Stejná měření po přidání kategoriální proměnné druh. Barva i vodorovná poloha nyní ukazují příslušnost ke skupině.

Po rozdělení vidíme silný posun: body tučňáků oslích leží převážně výše. Zároveň se hodnoty uvnitř každého druhu liší a oba soubory se částečně překrývají. Druh nám tedy pomohl odhalit strukturu, kterou šedý graf skrýval.

4.1 Přidáme průměry

Druh	Počet jedinců	Průměr (g)	SD (g)
tučňák kroužkový (Adélie)	151	3700.7	458.6
tučňák oslí (Gentoo)	123	5076.0	504.1

Průměr shrnuje polohu jedné skupiny, ale neříká, jak se liší jednotlivci uvnitř ní. Proto vedle něj zobrazíme směrodatnou odchylku (SD) i všechny body. Svislá úsečka kolem průměru sahá od průměru minus jedna SD po průměr plus jedna SD.




Obrázek 4: Body jsou jednotliví tučňáci, silné vodorovné úsečky jsou průměry a tenké svislé úsečky ukazují průměr $\pm$ 1 SD.

Průměr tučňáků oslích je o 1375.4 g vyšší než průměr tučňáků kroužkových. To je hlavní věcný rozdíl, který bude náš model popisovat.

5 Rozdíl průměrů

Dva průměry se mohou lišit o stejnou hodnotu, ale síla informace závisí také na variabilitě uvnitř skupin. Proto nyní na okamžik skryjeme jednotlivé body a ponecháme pouze tři součásti: dva průměry, jejich rozdíl a SD každé skupiny.




Obrázek 5: Silné vodorovné úsečky jsou průměry, svislé úsečky ukazují ± 1 SD a závorka vpravo měří rozdíl mezi průměry. Celkový rozsah dat zde záměrně nezobrazujeme.

Svislá závorka měří systematický rozdíl, který chceme vysvětlit druhem. Úsečky SD připomínají, že každý průměr zastupuje celý oblak různých jedinců. Rozdíl průměrů proto nikdy nebudeme číst bez informace o variabilitě kolem nich.

5.1 Stejný rozdíl, jiná variabilita

Následující obrázek není další výběr tučňáků. Je to záměrně zjednodušený myšlenkový pokus: všechny tři panely mají stejné dva průměry, ale liší se rozptýlením bodů kolem nich.



Obrázek 6: Myšlenkový pokus: rozdíl mezi průměry je ve všech třech panelech stejný. Body a úsečky průměr ± 1 SD ukazují rostoucí variabilitu uvnitř skupin.

Co by se změnilo v našem závěru?

Když je rozdíl mezi průměry ve všech panelech stejný, ve kterém panelu bude nejobtížnější odlišit systematický rozdíl od běžných rozdílů mezi jedinci (druh vysvětluje největší část celkové variability)?


Rozdíl průměrů tedy nečteme izolovaně. Posuzujeme jej vzhledem k variabilitě, která zůstává kolem skupinových průměrů. Právě z tohoto porovnání později vznikne název analýza rozptylu: metoda porovnává variabilitu zachycenou rozdílnými skupinovými průměry s reziduální variabilitou uvnitř skupin.

Dosud jsme rozdíl hmotností pouze popsali. Teď chceme udělat další krok: **fitovat lineární model a pomocí něj otestovat, zda jsou pozorované rozdíly mezi skupinovými průměry slučitelné s nulovým rozdílem.** Odezvou bude hmotnost těla a prediktorem druh. Než ale do známé formule vložíme kategoriální proměnnou, připomeneme si přesně, jak model pracoval s číselným prediktorem.

6 Stejný lineární model, jiný prediktor

6.1 Opakování


Než do modelu vložíme druh, vraťme se podrobně k modelu s číselným prediktorem. V lekci o vztahu dvou číselných proměnných jsme zobrazovali vztah dvou tělesných měření bodem pro každého tučňáka; později jsme tento vztah popsali přímkou. Zde použijeme délku zobáku jako prediktor hloubky zobáku.



Obrázek 7: Schéma měření délky a hloubky zobáku v datech Palmer Penguins. Ilustrace: Allison Horst.

6.2 Začneme daty a přímkou


Každý bod je jeden tučňák. Délka zobáku určuje jeho vodorovnou polohu a přímka ukazuje, jakou hloubku zobáku model pro tuto délku odhaduje.



Obrázek 8: Pozorované délky a hloubky zobáku s odhadnutou přímkou. Každá hodnota číselného prediktoru vybírá jedno místo na přímce.

6.3 Kde je intercept?


Intercept a je odhadnutá hloubka zobáku při délce zobáku 0 mm. Nula leží daleko mimo rozsah pozorovaných délek, proto plnou přímku prodloužíme čárkovane až k hodnotě $a = 20.89$ mm. Intercept umíme v rovnici vypočítat, ale pro tyto tučňáky je extrapolací.



Obrázek 9: Intercept je výška přímky při hodnotě prediktoru 0. Čárkovaná část upozorňuje, že mezi nulou a nejkratším pozorovaným zobákem nemáme žádná data.

6.4 Kde je sklon?


Sklon b je změna odhadnuté hloubky při prodloužení zobáku o 1 mm. Jedna jednotka by byla v grafu téměř neviditelná, proto zvýrazníme změnu délky o 10 mm. Odpovídající změna výšky přímky je $10b = -0.85$ mm.



Obrázek 10: Sklon převádí změnu prediktoru na změnu odhadnuté hodnoty. Zde je kvůli čitelnosti zobrazena změna při prodloužení zobáku o 10 mm.

6.5 Kde je residuum?

Residuum je svislá vzdálenost naměřené hodnoty od hodnoty na přímce. U zvýrazněného tučňáka tedy porovnáme naměřenou hloubku 20 mm s odhadem modelu 16.61 mm.



Obrázek 11: Residuum jednoho pozorování je svislá vzdálenost mezi naměřenou hodnotou a odhadnutou hodnotou na přímce.

6.6 Fitujeme připomenutý model v R

Teď můžeme přímku z grafů skutečně fitovat. Funkce `lm()` vrátí stejné dva koeficienty, které jsme ve figurech hledali odděleně.

```
mod_zobak <-  
  lm(  
    formula = hloubka_zobaku_mm ~ delka_zobaku_mm,  
    data = data_tucnaci  
  )  
  
coef(mod_zobak)
```

```
(Intercept) delka_zobaku_mm  
20.88546832   -0.08502128
```

Řádek `(Intercept)` je koeficient $a = 20.885$: **intercept**, tedy výška přímky při délce zobáku 0 mm. Řádek `delka_zobaku_mm` je koeficient $b = -0.085$: **sklon**, tedy změna odhadnuté hloubky při prodloužení zobáku o 1 mm.

$$\hat{y}_i = \underbrace{a}_{\text{intercept}} + \underbrace{b}_{\text{sklon}} x_i = 20.885 + (-0.085)x_i.$$

Výstup `coef()` se tak přímo vrací ke dvěma předchozím obrázkům: první číslo určuje bod přímky při $x = 0$ a druhé určuje její sklon. Residuum pak stále měří svislou vzdálenost konkrétního pozorování od této přímky.

U číselného prediktoru jsme tedy naměřenou hodnotu rozdělili na hodnotu odhadnutou modelem a residuum:

$$\text{naměřená hodnota} = \text{odhadnutá hodnota} + \text{residuum}.$$

Pro konkrétní přímku je odhadnutá hodnota $a + bx_i$; obecný zápis zůstává:

$$y_i = \hat{y}_i + e_i = a + bx_i + e_i.$$

Číslo x_i určovalo polohu pozorování na vodorovné ose. Výraz $a + bx_i$ potom vybral odpovídající výšku na přímce. Intercept, sklon a residuum jsme proto nehledali najednou: každý má v modelu jinou roli a v grafu jiné místo. Nyní ale prediktor obsahuje názvy druhů. Aby mohl vstoupit do stejného výpočtu, model si z něj vytvoří číselnou proměnnou.


7 Lineární model s kategoriální proměnnou

Teď opustíme zobáky a vrátíme se k hlavní biologické otázce: **liši se průměrná hmotnost Adélie a Gentoo?** Odezvou je znovu hmotnost těla v gramech. Místo číselné délky zobáku ale modelu předáváme název druhu.

Lineární model potřebuje způsob, jak dvě kategorie vložit do rovnice. Pro dva druhy stačí binární proměnná „**je Gentoo?**“: hodnota 0 znamená „ne“, tedy Adélie, a hodnota 1 znamená „ano“, tedy Gentoo. Nejde o nové biologické měření ani pořadí druhů. Je to pouze číselný zápis příslušnosti ke skupině. Nejdříve jej ukážeme jako nový sloupec vedle dvou skutečných pozorování.

Druh	Naměřená hmotnost (g)	je Gentoo?
tučňák kroužkový (Adélie)	3750	0
tučňák oslí (Gentoo)	4500	1

Nyní stejnou proměnnou použijeme jako vodorovnou osu. Model stále dostává přesně hodnotu 0 nebo 1. Jednotlivé body v každé skupině pouze nepatrně posuneme doleva a doprava, aby se navzájem nepřekrývaly; tento zobrazovací posun nevytváří nové hodnoty prediktoru. Vodorovné úsečky jsou dvě odhadnuté hodnoty a tečkované svislice jsou vzdálenosti jednotlivých měření od těchto odhadů.



Obrázek 12: Kategorie druhu zapsaná binární proměnnou 0/1. Model přiřadí všem jedincům s hodnotou 0 průměr Adélie a všem jedincům s hodnotou 1 průměr Gentoo. Body jsou jen kvůli překryvu mírně posunuty do stran; tečkované úsečky jsou residua.

Nula a jednička nejsou další biologická měření a neříkají, že jeden druh je „vyšší“ nebo „lepší“. Jsou jen jazykem, kterým modelu sdělíme příslušnost ke skupině. Stejně jako u číselného prediktoru zůstává odhadnutá hodnota ve tvaru intercept plus koeficient krát hodnota prediktoru.

7.1 Odvození rovnice

Rovnici odvodíme ze dvou hodnot přepínače. **Intercept** a bude průměrnou hmotností referenčního druhu Adélie. **Koeficient** b bude rozdíl mezi průměrem Gentoo a průměrem Adélie. U číselného prediktoru byl b sklon; zde má nový význam skupinového rozdílu.

$$\text{odhadnutá hmotnost těla} = \underbrace{\text{průměrná hmotnost druhu Adélie}}_{\text{intercept } a} + \underbrace{\text{rozdíl Gentoo vůči Adélie}}_{\text{koeficient } b} \cdot \text{„je Gentoo?“} .$$

Pro Adélie má přepínač hodnotu 0:

$$\begin{aligned}\text{odhadnutá hmotnost Adélie} &= 3700.7 + 1375.4 \cdot 0 \\ &= 3700.7 \text{ g} .\end{aligned}$$

Pro Gentoo má přepínač hodnotu 1:

$$\begin{aligned}\text{odhadnutá hmotnost Gentoo} &= 3700.7 + 1375.4 \cdot 1 \\ &= 5076 \text{ g} .\end{aligned}$$

Až teď použijeme obecné symboly. z_i je přepínač příslušnosti ke skupině:

$$\begin{aligned}\hat{y}_i &= a + bz_i, \\ y_i &= a + bz_i + e_i.\end{aligned}$$

Zápis se od číselného prediktoru téměř nezměnil. Změnil se význam proměnné na pravé straně a tím i význam koeficientu b : už nepopisuje změnu při zvýšení prediktoru o jednu měrnou jednotku, ale rozdíl jedné skupiny vůči referenční skupině.

Nula a jednička nejsou pořadí druhů

Kdybychom vyměnili referenční druh, změnil by se přepínač, intercept i znaménko koeficientu. Skupinové průměry a biologický obsah dat by však zůstaly stejné. Kódování je jazyk modelu, ne vlastnost tučňáků.

Ve studii s kontrolou nastavte referenci záměrně

Pokud má studie skutečnou kontrolní skupinu, je obvykle nejčitelnější nastavit ji jako referenci. Intercept potom vyjadřuje průměr kontroly a každý léčebný koeficient odpovídá přímo otázce **ošetření minus kontrola**.

```
data_studie$skupina <-  
  relevel(  
    x = data_studie$skupina,  
    ref = "kontrola"  
  )  
  
levels(data_studie$skupina)
```

Tato volba pouze zpřehlední koeficienty. Nevytváří randomizaci, kontrolní podmínku ani kauzální důkaz — ty závisejí na designu studie. Změna reference také nemění fitované skupinové průměry, residua ani celkový test modelu.

8 Fitujeme dvouskupinový model v R

V R zůstává funkce `lm()` stejná. Do pravé strany formule jednoduše vložíme `druh`. R ale musí rozhodnout, vůči kterému druhu bude zapisovat rozdíl. Proto zvolí jednu úroveň faktoru jako **referenční skupinu**.

Ve výchozím kódování používá R jako referenci první úroveň faktoru. V doplňujícím bloku při přípravě dat jsme pořadí nastavili na `Adelie`, `Chinstrap`, `Gentoo`; po ponechání dvou druhů proto zůstane první Adélie. Volba reference je nutná, protože informace „je Adélie?“ a „je Gentoo?“ jsou u dvou druhů navzájem dokonale propojené: známe-li jednu odpověď, druhou už dopočítáme. Model proto použije jeden společný základ - intercept reference - a jeden rozdíl druhé skupiny vůči němu.

```
# Ponecháme dva druhy a odstraníme nevyužitou třetí úroveň
data_dva_druhy <-
  data_tucnaci[
    data_tucnaci$druh %in% c("Adelie", "Gentoo"),
  ]
data_dva_druhy$druh <- droplevels(data_dva_druhy$druh)

# Zkontrolujeme pořadí úrovní; první je reference
levels(data_dva_druhy$druh)
```

```
[1] "Adelie" "Gentoo"
```

```
# Fitujeme známý lineární model s kategoriálním prediktorem
mod_dva_druhy <-
  lm(
    formula = hmotnost_tela_g ~ druh,
    data = data_dva_druhy
  )

# Nejdříve si prohlédneme celý známý výstup modelu
summary(mod_dva_druhy)
```

Call:

```
lm(formula = hmotnost_tela_g ~ druh, data = data_dva_druhy)
```

Residuals:

Min	1Q	Median	3Q	Max
-1126.02	-369.50	-26.02	343.00	1223.98

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	3700.66	39.02	94.83	<2e-16	***
druhGentoo	1375.35	58.24	23.61	<2e-16	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1


Residual standard error: 479.5 on 272 degrees of freedom

Multiple R-squared: 0.6721, Adjusted R-squared: 0.6709

F-statistic: 557.6 on 1 and 272 DF, p-value: < 2.2e-16

Řádek výstupu	Odhad (g)	Biologický význam	Kde číslo vidíme v grafu
(Intercept)	3700.7	průměrná hmotnost Adélie	vzdálenost průměrové úsečky Adélie od nuly
druhGentoo	1375.4	průměr Gentoo minus průměr Adélie	svislá vzdálenost mezi dvěma průměry

Tabulka nám přeložila řádky výstupu do slov. Teď stejná dvě čísla znovu umístíme do grafu: intercept je výška průměru Adélie od nuly a koeficient `druhGentoo` je vzdálenost od průměru Adélie k průměru Gentoo.



Obrázek 13: Dva koeficienty dvouskupinového modelu přímo v datech. Intercept a je vzdálenost průměrové úsečky Adélie od nuly; koeficient b je rozdíl Gentoo minus Adélie.

Intercept 3700.7 g je průměr referenční skupiny Adélie. Koeficient `druhGentoo` 1375.4 g je rozdíl **Gentoo minus Adélie**. Součet obou koeficientů dává 5076 g, tedy průměr Gentoo.

Doplňující: co se změní, když zvolíme jinou referenci?

Referenci můžeme změnit funkcí `relevel()`. Když jako základ zvolíme Gentoo, intercept se stane průměrem Gentoo a rozdílový koeficient bude Adélie minus Gentoo. Odhadnuté skupi-

nové průměry, residua i biologický obsah modelu zůstanou stejné; změní se pouze způsob jejich zápisu.

```
data_reference_gentoo <- data_dva_druhy
data_reference_gentoo$druh <-
  relevel(
    x = data_reference_gentoo$druh,
    ref = "Gentoo"
  )

levels(data_reference_gentoo$druh)
```

```
[1] "Gentoo" "Adelie"
```

```
mod_reference_gentoo <-
  lm(
    formula = hmotnost_tela_g ~ druh,
    data = data_reference_gentoo
  )

coef(mod_reference_gentoo)
```

```
(Intercept)  druhAdelie
 5076.016    -1375.354
```


Při referenci Gentoo je intercept 5076 g a koeficient `druhAdelie` je -1375.4 g. Součet opět vrátí průměr Adélie 3700.7 g.

Co netestuje řádek interceptu

P-hodnota v řádku interceptu porovnává průměr Adélie s nulovou hmotností. Nulová hmotnost není naše biologická otázka. Otázku rozdílu druhů ve dvouskupinovém modelu najdeme v řádku `druhGentoo`.

9 Odhadnuté hodnoty a residua nezmizely

V modelu s číselným prediktorem měla každá délka zobáku vlastní hodnotu na přímce. V modelu se dvěma skupinami existují jen dvě odhadnuté hodnoty: průměr Adélie a průměr Gentoo. Každý jedinec stejného druhu dostane stejnou odhadnutou hmotnost, ale vlastní residuum.



Obrázek 14: Každý jedinec sdílí odhadnutou hodnotu svého druhu. Body jsou kvůli překryvu mírně posunuty do stran. Tenké svislé úsečky spojují skutečné body s odhadem a jsou tedy residui; jedno residuum je zvýrazněno.

Pro prvního zobrazeného jedince platí nejprve vztah slovy:

$$\text{residuum} = \text{naměřená hmotnost} - \text{odhadnutá hmotnost} .$$

Dosadíme čísla ze stejného řádku dat a z výšky průměrové úsečky:

$$\begin{aligned} \text{residuum} &= 4775 - 3700.7 \\ &= 1074.3 \text{ g} . \end{aligned}$$

Teprve potom se vrátíme k obecnému zápisu:

$$e_i = y_i - \hat{y}_i .$$

```

# Z modelu získáme odhadnutou hmotnost každého jedince
data_dva_druhy$odhadnuta_hmotnost_g <-
  fitted(mod_dva_druhy)

# Residuum je měření minus odhadnutá hodnota
data_dva_druhy$residuum_g <-
  resid(mod_dva_druhy)

# Zkontrolujeme první řádky obou nových sloupců
head(
  data_dva_druhy[
    , c(
      "druh",
      "hmotnost_tela_g",
      "odhadnuta_hmotnost_g",
      "residuum_g"
    )
  ]
)

```

	druh	hmotnost_tela_g	odhadnuta_hmotnost_g	residuum_g
1	Adelie	3750	3700.662	49.33775
2	Adelie	3800	3700.662	99.33775
3	Adelie	3250	3700.662	-450.66225
5	Adelie	3450	3700.662	-250.66225
6	Adelie	3650	3700.662	-50.66225
7	Adelie	3625	3700.662	-75.66225

Co zůstalo stejné

Lineární model stále rozděluje každou naměřenou hodnotu na systematickou část a residuum. U číselného prediktoru byla systematickou částí přímka; u kategoriálního prediktoru jsou jí skupinové průměry.

10 Jak velký a přesný je rozdíl dvou druhů?

Z dlouhého výstupu `summary()` nyní vytáhneme jen dva odhadnuté koeficienty. Funkce `coef()` je užitečná právě ve chvíli, kdy víme, na které hodnoty se chceme zaměřit:

```
coef(mod_dva_druhy)
```

```
(Intercept)  druhGentoo  
      3700.662      1375.354
```

Koeficient `druhGentoo` odhaduje rozdíl 1375.4 g. Nyní navážeme na předchozí dvě lekce: odhad doplníme standardní chybou a 95% intervalem spolehlivosti.

Interval nevzniká jako další nezávislé číslo. Vypočítáme jej ze stejného odhadu a standardní chyby:

$$95\% \text{ interval} = \hat{b} \pm \underbrace{t_{0,975,df}}_{\text{kritická hodnota}} \cdot \text{SE}(\hat{b}).$$

Pro 95% interval necháváme 2,5 % t-rozdělení v každém krajním chvostu. Kritická hodnota proto závisí na zvolené hladině 95 % a na 272 residuálních stupních volnosti; zde je 1.969.

```
# Vezmeme odhad a standardní chybu z řádku druhGentoo
tabulka_koeficientu <- coef(summary(mod_dva_druhy))
odhad_rozdilu <- tabulka_koeficientu["druhGentoo", "Estimate"]
standardni_chyba <- tabulka_koeficientu["druhGentoo", "Std. Error"]

# Kritická hodnota pro 95% interval a residuální stupně volnosti
kriticka_hodnota <-
  qt(
    p = 0.975,
    df = df.residual(mod_dva_druhy)
  )


dolni_mez <- odhad_rozdilu - kriticka_hodnota * standardni_chyba
horni_mez <- odhad_rozdilu + kriticka_hodnota * standardni_chyba

c(dolni_mez = dolni_mez, horni_mez = horni_mez)
```

```
dolni_mez horni_mez
1260.687 1490.021
```

```
# Stejný výpočet pohodlně provede confint()
confint(mod_dva_druhy)["druhGentoo", ]
```

```
2.5 % 97.5 %
1260.687 1490.021
```



Obrázek 15: Odhad rozdílu průměrné hmotnosti Gentoo minus Adélie a jeho 95% interval spolehlivosti. Nula znamená stejné průměry.

Interval sahá od 1260.7 do 1490 g. Celý leží nad nulou, ale jeho hlavním sdělením není pouze „nula uvnitř / nula vně“. Ukazuje také, jak velký rozdíl je s daty a modelem slučitelný.

10.1 Testujeme nulový rozdíl

Nulová hypotéza a alternativa nyní mluví o rozdílu průměrných hmotností:

$$H_0 : \text{průměr Gentoo} - \text{průměr Adélie} = 0,$$

$$H_A : \text{průměr Gentoo} - \text{průměr Adélie} \neq 0.$$

Než dosadíme čísla, znovu si zobrazíme celý výstup modelu. V řádku `druhGentoo` stojí vedle sebe všechny tři hodnoty, které potřebujeme: odhad rozdílu, jeho standardní chyba a vypočtená t-statistika.

```
summary(mod_dva_druhy)
```

Call:

```
lm(formula = hmotnost_tela_g ~ druh, data = data_dva_druhy)
```

Residuals:

Min	1Q	Median	3Q	Max
-1126.02	-369.50	-26.02	343.00	1223.98

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	3700.66	39.02	94.83	<2e-16 ***
druhGentoo	1375.35	58.24	23.61	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 479.5 on 272 degrees of freedom

Multiple R-squared: 0.6721, Adjusted R-squared: 0.6709

F-statistic: 557.6 on 1 and 272 DF, p-value: < 2.2e-16

V řádku `druhGentoo` tedy čteme `Estimate = 1375.35`, `Std. Error = 58.24` a `t value = 23.61`. Následující rovnice pouze ukazuje, jak R ze dvou prvních sloupců získalo třetí.

Z předchozí lekce známe vztah mezi odhadem, nulovou hodnotou a jeho nejistotou. Nejdříve jej zapíšeme slovy:

$$t\text{-statistika} = \frac{\text{odhadnutý rozdíl} - \text{nulový rozdíl}}{\text{standardní chyba rozdílu}}.$$

Potom dosadíme čísla z řádku `druhGentoo`:

$$\begin{aligned} t &= \frac{1375.4 - 0}{58.2} \\ &= 23.61. \end{aligned}$$

Až nakonec použijeme obecný zápis:


$$t = \frac{\hat{b} - 0}{\text{SE}(\hat{b})}.$$

Stejně jako v předchozí lekci můžeme výsledek umístit do t-rozdělení očekávaného při nulové hypotéze. Musíme ale rozlišit dvě různá čísla:

- **kritické hranice** jsou zde -1.969 a $+1.969$. Oddělují prostředních 95 % nulového t-rozdělení od krajních 5 %: v každém chvostu zůstává 2,5 %. Stejnou kladnou kritickou hodnotu jsme použili už při výpočtu 95% intervalu spolehlivosti;
- **pozorovaná t-statistika** je $+23.61$. Tu jsme právě vypočítali z řádku `druhGentoo` v `summary()`.

Kritické hranice tedy **nejso** výsledkem našeho testu. Vymezují předem zvolené rozhodovací oblasti pro $\alpha = 0,05$. Náš výsledek $t = +23.61$ leží mnohem dále od nuly. Protože testujeme oboustrannou otázku, sledujeme také stejně vzdálenou zrcadlovou hranici -23.61 . P-hodnota je součet ploch nulového t-rozdělení za těmito dvěma hranicemi, nikoli plocha za kritickými hodnotami.

Následující graf proto používá dva panely: první zvětší kritické hranice a oblasti o celkové ploše $\alpha = 0,05$; druhý ukáže skutečně pozorované t a jeho zrcadlovou hranici na celé ose.



Obrázek 16: T-rozdělení při nulové hypotéze. Levý panel ukazuje kritické hranice a fialové chvosty o celkové ploše $\alpha = 0,05$. V pravém panelu fialové čáry tyto hranice připomínají, zatímco oranžové pásy označují oblasti za pozorováním $t = 23,61$ a zrcadlovou hranicí $-23,61$. P-hodnota je plocha pod t-křivkou uvnitř těchto oranžových oblastí.

Pozorovaný rozdíl leží 23.61 standardních chyb nad nulou, takže skutečně pozorovaná t-statistika je $+23.61$. Záporná hodnota -23.61 nebyla pozorována; je to zrcadlová hranice potřebná pro oboustrannou otázku. Při 272 residuálních stupních volnosti je součet ploch za oběma hranicemi, tedy p-hodnota, $<0,001$. Za předpokladů modelu jsou data velmi obtížně slučitelná s přesně nulovým rozdílem mezi těmito dvěma druhy.

10.2 Historická poznámka: dvouvýběrový t-test v literatuře

Statistické metody se historicky vyučovaly jako soubor samostatně pojmenovaných testů pro různé situace: jeden test pro dva průměry, jiný pro více průměrů, další pro vztah dvou číselných proměnných. Takové názvy byly praktické v době ručních výpočtů a tabulek, a proto zůstávají v učebnicích, článcích i nabídkách statistických programů dodnes.

Mnoho těchto klasických postupů ale můžeme zapsat jako speciální případy jednoho regresního modelu. Dvoustupňový t-test se společným rozptylem používá za stejných předpokladů tentýž odhad rozdílu, standardní chybu, t-statistiku a p-hodnotu jako koeficient `druhGentoo` v našem dvoustupňovém lineárním modelu. Nemusíme se tedy učit nový způsob uvažování: biologickou otázku, odhad, nejistotu i test stále čteme z jednoho modelového rámce.

Název **dvouvýběrový t-test** však budeme potkávat v další literatuře. Následující příklad proto ukazuje, jak známý modelový výsledek přeložit do historického názvu testu a zpět. Nejde o další nesouvisející analýzu. Aby znaménko odpovídalo našemu koeficientu, odečteme Adélie od Gentoo.

Proč tento historický název uvádíme

Když v knize uvidíte dvouvýběrový t-test se společným rozptylem, můžete si jej představit jako lineární model `y ~ skupina` se dvěma úrovněmi. Při čtení výsledku se znovu ptejte na rozdíl průměrů, jeho standardní chybu, t-statistiku a p-hodnotu.

```
# Připravíme hmotnosti obou skupin ve směru Gentoo minus Adélie
vec_gentoo <-
  data_dva_druhy$hmotnost_tela_g[
    data_dva_druhy$druh == "Gentoo"
  ]
vec_adelie <-
  data_dva_druhy$hmotnost_tela_g[
    data_dva_druhy$druh == "Adelie"
  ]

# Test se společným rozptylem odpovídá dvouskupinovému lm()
t.test(
  x = vec_gentoo,
  y = vec_adelie,
  var.equal = TRUE
)
```

Two Sample t-test

```
data:  vec_gentoo and vec_adelie
t = 23.614, df = 272, p-value < 2.2e-16
alternative hypothesis: true difference in means is not equal to 0
95 percent confidence interval:
 1260.687 1490.021
sample estimates:
mean of x mean of y
 5076.016  3700.662
```


Postup	Rozdíl Gentoo – Adélie (g)	t-statistika	df
koeficient v lm()	1375.4	23.61	272
t-test se společným rozptylem	1375.4	23.61	272

Výchozí t.test() v R je Welchův test

Bez argumentu `var.equal = TRUE` používá R Welchův t-test, který nevyžaduje společný rozptyl skupin a může mít jiné stupně volnosti i mírně jiný interval. Není proto pravda, že každý výstup `t.test()` musí být číselně totožný s obyčejným `lm()`. Totožnost v tabulce platí pro stejnou otázku a stejné předpoklady.

11 Přidáme třetí druh, ale formule v R zůstane stejná

Nyní vrátíme do dat tučňáka uzdičkového. Do `lm()` nemusíme přidávat nový druh ručně: faktor `druh` už obsahuje všechny tři úrovně.



Obrázek 17: Tři druhy s průměrem ± 1 SD. Svislé závorky ukazují oba rozdíly, které model přímo vyjadřuje vůči referenčnímu druhu Adélie.

Průměry Adélie a Chinstrap leží blízko sebe, zatímco průměr Gentoo je mnohem výše. To je přesně situace, ve které potřebujeme odlišit tři otázky: jak se jednotlivé skupiny liší od reference, zda jsou všechny tři průměry celkově stejné a které konkrétní dvojice chceme porovnat.

```
# Fitujeme stejnou formuli na všech třech druzích
mod_tri_druhy <-
  lm(
    formula = hmotnost_tela_g ~ druh,
    data = data_tucnaci
  )

# Koeficienty stále čteme vzhledem k referenčnímu druhu Adélie
coef(mod_tri_druhy)
```

```
(Intercept)  druhChinstrap  druhGentoo
3700.66225    32.42598    1375.35401
```

```
confint(mod_tri_druhy)
```

```
                2.5 %    97.5 %
(Intercept)  3626.6655 3774.6590
druhChinstrap -100.3686 165.2206
druhGentoo    1264.9117 1485.7963
```

11.1 Tři skupiny potřebují dva přepínače

Adélie zůstává referencí. Model proto vytvoří přepínač pro Chinstrap a druhý pro Gentoo.

Druh	je Chinstrap?	je Gentoo?	Odhadnutá hmotnost
tučňák kroužkový (Adélie)	0	0	a
tučňák uzdičkový (Chinstrap)	1	0	a + b ₁
tučňák oslí (Gentoo)	0	1	a + b ₂

Nejdříve slovy:

odhadnutá hmotnost těla = průměr Adélie
 + rozdíl Chinstrap vůči Adélie · „je Chinstrap?“
 + rozdíl Gentoo vůči Adélie · „je Gentoo?“ .

Ted' dosadíme skutečné koeficienty a oba přepínače z tabulky. Každý řádek skončí právě na průměru daného druhu:

$$\begin{aligned}\widehat{\text{hmotnost}}_{\text{Adélie}} &= 3700.7 + 32.4 \cdot 0 + 1375.4 \cdot 0 = 3700.7 \text{ g}, \\ \widehat{\text{hmotnost}}_{\text{Chinstrap}} &= 3700.7 + 32.4 \cdot 1 + 1375.4 \cdot 0 = 3733.1 \text{ g}, \\ \widehat{\text{hmotnost}}_{\text{Gentoo}} &= 3700.7 + 32.4 \cdot 0 + 1375.4 \cdot 1 = 5076 \text{ g} .\end{aligned}$$

Až potom vztah zapíšeme obecně. Symbol $z_{\text{Chinstrap},i}$ je číselná odpověď na otázku „je pozorování i Chinstrap?“ a $z_{\text{Gentoo},i}$ na otázku „je pozorování i Gentoo?“. Oba nabývají hodnoty 0 nebo 1. Koeficient a je průměr Adélie a b_1 , b_2 jsou rozdíly dalších druhů vůči Adélie:

$$\hat{y}_i = a + b_1 z_{\text{Chinstrap},i} + b_2 z_{\text{Gentoo},i} .$$

Řádek výstupu	Odhad (g)	Význam při referenci Adélie
(Intercept)	3700.7	průměr Adélie
druhChinstrap	32.4	Chinstrap minus Adélie
druhGentoo	1375.4	Gentoo minus Adélie

Koeficienty neobsahují všechny dvojice

Tabulka s referencí Adélie přímo odpovídá na otázky Chinstrap minus Adélie a Gentoo minus Adélie. Rozdíl Gentoo minus Chinstrap v ní není samostatný řádek, i když jej lze ze stejného modelu odvodit.

12 Jedna celková otázka: analýza rozptylu

U dvou skupin stačil jediný koeficient: Gentoo minus Adélie. U tří skupin už model obsahuje dva rozdílové koeficienty a jejich samostatné řádky neodpovídají přímo na jednu společnou otázku. Nejdříve se proto ptáme, zda přidání proměnné `druh` zlepší popis dat jako celek:

$$H_0 : \text{všechny tři průměrné hmotnosti jsou stejné} .$$

Alternativa neříká, která dvojice se liší. Říká pouze, že alespoň jeden průměr není stejný jako ostatní.

12.1 Jeden společný průměr proti třem skupinovým průměrům

Nulová hypotéza odpovídá jednoduššímu modelu bez prediktoru: všem tučňákům přiřadí jeden společný průměr. Model s druhem je složitější a přiřadí každému jedinci průměr jeho druhu. Otázku analýzy rozptylu proto můžeme přeformulovat: **zkrátí tři skupinové průměry residua natolik, aby přidaná složitost modelu stála za to?**




Obrázek 18: Stejná pozorování popsána jedním společným průměrem a třemi skupinovými průměry. Body jsou kvůli překryvu mírně posunuty do stran. Tečkované svislice jsou všechna residua; šipky v levém panelu ukazují posun od společného průměru k průměrům druhů.

V levém panelu jsou residua vzdálenosti od jednoho společného průměru. V pravém panelu jsou vzdálenosti od průměru vlastního druhu. Součet čtverců residuí klesne z 219 307 697 na 72 443 483 g^2 . Rozdílné skupinové průměry tedy vysvětlí část variability, která v jednodušším modelu zůstávala v residuích.

Proč residua umocňujeme? Kdybychom pouze sečetli kladné a záporné vzdálenosti od průměru, navzájem by se vyrušily. Čtverce jsou vždy nezáporné a velkým odchylkám dávají větší váhu. Stejnou myšlenku součtu čtverců residuí už známe z fitování přímky.

Pokles součtu čtverců můžeme zobrazit jako rozdělení původní chyby jednoduššího modelu na dvě části:

$$\underbrace{\text{SSE jednoho průměru}}_{219307697} = \underbrace{\text{SS zachycený druhem}}_{146864214} + \underbrace{\text{SSE tří průměrů}}_{72443483}$$



Obrázek 19: Původní součet čtverců residuí se po přidání druhu rozdělí na část zachycenou rozdíly skupinových průměrů a část, která stále zůstává uvnitř druhů.

12.2 Co porovnává F-statistika

Samotný pokles součtu čtverců nestačí. Složitější model téměř vždy residua alespoň trochu zkrátí, protože dostal více koeficientů. Potřebujeme proto porovnat dvě veličiny na férovém měřítku:

1. kolik variability zachytil každý přidaný rozdíl mezi skupinami;
2. jak velký čtverec residua typicky zůstává uvnitř skupin.

F-statistika je poměr právě těchto dvou množství. Proto je zde a proto se metoda jmenuje **analýza rozptylu**, i když biologická otázka mluví o průměrech.

Nejdříve stejný vztah zapíšeme pouze slovy:

$$\text{F-statistika} = \frac{\text{variabilita připadající na rozdíly mezi skupinami}}{\text{reziduální variabilita uvnitř skupin}}.$$

Čísla už jsme viděli ve dvou konkrétních grafech. V grafu **jeden společný průměr proti třem skupinovým průměrům** byl součet čtverců residuí jednoho průměru 219 307 697 g² a součet čtverců residuí tří průměrů 72 443 483 g². Jejich rozdíl 146 864 214 g² tvoří fialovou část grafu rozkladu součtu čtverců - část zachycenou druhem.

Součty čtverců nyní převedeme na srovnatelné **průměrné čtverce** dělením příslušnými stupni volnosti. Model přidal 2 rozdílové koeficienty; uvnitř skupin zbývá 339 residuálních stupňů volnosti:

$$\text{průměrný čtverec mezi skupinami} = \frac{219\,307\,697 - 72\,443\,483}{2} = \frac{146\,864\,214}{2} = 73\,432\,107,$$

$$\text{průměrný čtverec uvnitř skupin} = \frac{72\,443\,483}{339} = 213\,698.$$

Kdyby druh nepomáhal, zlepšení připadající na jeden nový koeficient by bylo podobně velké jako běžný čtverec residua a F by bývalo kolem 1. Čím je čitatel větší vůči jmenovateli, tím více skupinové rozdíly vyčnívají nad variabilitu jedinců uvnitř skupin. V našich datech jejich poměr dává:

$$F = \frac{73\,432\,107}{213\,698} = 343.63.$$

Až teď zapíšeme stejnou myšlenku obecně:

$$F = \frac{MS_{\text{mezi skupinami}}}{MS_{\text{uvnitř skupin}}}.$$

Symbol MS označuje průměrný čtverec (*mean square*): součet čtverců dělený příslušnými stupni volnosti. F-statistika tak spojuje všechny předchozí kroky: rozdíly průměrů mění odhadnuté hodnoty, tím zkracují residua, z residuí počítáme součty čtverců a jejich férově přepočtený poměr testuje společnou nulovou hypotézu.

```
# Položíme celkovou otázku stejnému třískupinovému modelu
anova(mod_tri_druhy)
```

Analysis of Variance Table

Response: hmotnost_tela_g

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
druh	2	146864214	73432107	343.63	< 2.2e-16 ***
Residuals	339	72443483	213698		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

12.3 Jak číst tabulku `anova()` řádek po řádku

Tabulka je kompaktní, ale každý údaj odpovídá kroku, který jsme už viděli v rovnici nebo grafu:

1. **Řádek druh** popisuje část variability zachycenou přidáním tří skupinových průměrů místo jednoho společného průměru. **Řádek Residuals** popisuje variabilitu, která zůstává kolem skupinových průměrů.
2. **Df pro druh je 2**. Tři skupinové průměry vyjádříme jedním referenčním průměrem a dvěma rozdíly, takže druh přidává $3 - 1 = 2$ stupně volnosti. **Df pro residua je 339**. Máme 342 pozorování a odhadujeme tři skupinové průměry, proto zbývá $342 - 3 = 339$ residuálních stupňů volnosti.
3. **Sum Sq pro druh je 146 864 214 g²**. Je to přesně rozdíl mezi SSE jednoho a tří průměrů a fialová část předchozího rozkladového grafu. **Sum Sq pro Residuals je 72 443 483 g²**, tedy šedá část, která zůstává uvnitř druhů.
4. **Mean Sq** vznikne vydělením každého Sum Sq jeho Df: $73\,432\,107\text{ g}^2$ mezi skupinami a $213\,698\text{ g}^2$ uvnitř skupin.
5. **F value je 343.63**. Je to poměr těchto dvou průměrných čtverců. Hodnota mnohem větší než 1 znamená, že rozdíly skupinových průměrů jsou velké vůči běžné variabilitě jedinců kolem těchto průměrů.
6. **Pr(>F) je p-hodnota**. Nejde o další nezávislý výpočet z dat; vzniká umístěním pozorovaného F do nulového F -rozdělení se dvěma stupni volnosti pro čitatel a 339 pro jmenovatel.

12.4 Jak se z F-statistiky stane p-hodnota


Pokud by všechny tři populační průměry byly stejné a platily předpoklady modelu, opakované výběry by vytvářely hodnoty z F -rozdělení $F(2, 339)$. P-hodnota je plocha napravo od naší pozorované hodnoty 343.63:

$$p = (F_{2,339} \geq 343.63 \mid H_0).$$

```
pf(
  q = f_anova,
  df1 = df_group,
  df2 = df_residual,
  lower.tail = FALSE
)
```

```
[1] 2.892368e-82
```

Argument `lower.tail = FALSE` říká R, že chceme pravý chvost: pravděpodobnost hodnot stejně velkých nebo větších než pozorované F . U našeho modelu je tato plocha tak malá, že ji v grafu prakticky neuvidíme.



Obrázek 20: F-rozdělení očekávané při nulové hypotéze. Levý panel ukazuje běžné hodnoty blízko jedné; pravý panel umísťuje pozorovanou F-statistiku na skutečnou osu. P-hodnota je plocha napravo od oranžové čáry a je zde příliš malá, aby byla viditelná.

Pro tučňáky tedy vychází $F(2, 339) = 343.63$ a p-hodnota má hodnotu $<0,001$. Za předpokladů modelu jsou data velmi obtížně slučitelná s hypotézou, že všechny tři druhy mají stejnou průměrnou hmotnost.

Celkový výsledek neříká, že se liší každá dvojice

Malá p-hodnota analýzy rozptylu podporuje tvrzení, že alespoň jeden průměr se liší. Neurčuje však, které dvojice se liší, ani zda jsou všechny rozdíly biologicky důležité.

13 Post-hoc: které dvojice se liší?

Celkovou otázku jsme už vyhodnotili pomocí F-testu: data jsou obtížně slučitelná s hypotézou tří stejných průměrů. **Teprve teď** přecházíme od této jediné celkové otázky k navazujícím otázkám o konkrétních dvojicích. U tří druhů existují tři páry: Chinstrap minus Adélie, Gentoo minus Adélie a Gentoo minus Chinstrap.

Nejdříve celkový test, teprve potom post-hoc porovnání

1. Funkcí `anova()` nejprve testujeme společnou nulovou hypotézu, že jsou **všechny skupinové průměry stejné**.
2. Až po vyhodnocení tohoto celkového testu získáme ze stejného modelu odhadnuté skupinové průměry a položíme post-hoc otázku, **ktelé konkrétní dvojice** se liší.

Tukeyho metoda tedy není náhradou za celkový F-test. Je to post-hoc porovnání: navazující krok, který podrobněji rozebírá rozdíl zachycený celkovým testem.

Kdybychom každý pár testovali jako izolovanou novou studii, s rostoucím počtem testů by rostla šance na alespoň jeden náhodně extrémní výsledek. Tukeyho post-hoc metoda proto vyhodnotí rodinu navazujících otázek společně. Získáme simultánní intervaly a p-hodnoty upravené pro všechna tři porovnání.

Doplňující: proč jsou Tukeyho intervaly širší

Obyčejný pětadevadesátiprocentní interval chrání dlouhodobé pokrytí jedné předem vybrané veličiny. Zde ale chceme současně číst tři rozdíly. Kdyby měl každý neopravený interval pětiprocentní riziko minutí, šance, že alespoň jeden z celé sady mine svou skutečnou hodnotu, by byla větší než pět procent.

Tukeyho metoda proto nastaví jednotlivé intervaly opatrněji tak, aby přibližně devadesát pět procent opakovaných **celých sad tří intervalů** pokrylo všechny tři skutečné rozdíly současně. Za tuto společnou ochranu obvykle platíme širšími intervaly a většími upravenými p-hodnotami než při izolovaném čtení jediné dvojice.

Doplňující: plánované kontrasty a post-hoc porovnání nejsou stejná otázka

V této lekci nejprve klademe celkovou otázku a potom systematicky prohlížíme všechny tři dvojice. To je post-hoc postup. Výzkumník však někdy ještě před sběrem dat určí jeden biologicky motivovaný kontrast, například „potápěčský druh proti průměru dvou pobřežních druhů“. Taková otázka není dodatečným hledáním nejzajímavější dvojice.

Předem plánovaný kontrast může být věcně přesnější než všechna párová srovnání a nemusí čekat na to, zda celkový F-test překročí jednu rozhodovací hranici. Stále však musíme transparentně uvést všechny plánované otázky a při více kontrastech zvážit jejich společnou chybovost. Výpočet kontrastů patří do pokročilejší práce s modely.

Funkce `emmeans()` pracuje přímo s již fitovaným objektem `mod_tri_druhy`. **Nefitujeme nový model.** Pouze z téhož lineárního modelu získáme průměrnou hmotnost odhadnutou pro každý druh. V tomto jednoduchém modelu s jediným kategoriálním prediktorem jsou tyto hodnoty stejné jako skupinové průměry, které už známe z grafu.

```
# Ze stejného modelu získáme odhadnutý průměr každého druhu
prumery_druhu <-
  emmeans::emmeans(
    object = mod_tri_druhy,
    specs = ~ druh
  )

prumery_druhu
```

druh	emmean	SE	df	lower.CL	upper.CL
Adelie	3701	37.6	339	3627	3775
Chinstrap	3733	56.1	339	3623	3843
Gentoo	5076	41.7	339	4994	5158

Confidence level used: 0.95

Výstup objektu `prumery_druhu` ukazuje všechny tři průměry odhadnuté modelem. Sloupec `emmean` obsahuje průměrnou hmotnost: 3700.7 g pro Adélie, 3733.1 g pro Chinstrap a 5076 g pro Gentoo. Sloupec `SE` je standardní chyba každého průměru, `df` udává residuální stupně volnosti a `lower.CL` s `upper.CL` vymezují 95% interval pro každý skupinový průměr zvlášť.

Tyto intervaly popisují nejistotu jednotlivých průměrů; samy ještě nejsou intervaly jejich vzájemných rozdílů. Teprve mezi odhadnutými průměry nyní vytvoříme všechny tři post-hoc rozdíly. Metoda `revpairwise` zachová směr, který jsme používali v grafech: Chinstrap minus Adélie, Gentoo minus Adélie a Gentoo minus Chinstrap. Argument `adjust = "tukey"` říká, že intervaly a p-hodnoty mají zohlednit celou rodinu tří porovnání.

```
# Až po celkovém F-testu provedeme post-hoc párová porovnání
post_hoc_druhy <-
  emmeans::contrast(
    object = prumery_druhu,
    method = "revpairwise",
    adjust = "tukey"
  )

summary(
  object = post_hoc_druhy,
  # První TRUE zobrazí intervaly, druhé t-testy a p-hodnoty
  infer = c(TRUE, TRUE)
)
```

```
contrast      estimate    SE  df lower.CL upper.CL t.ratio p.value
Chinstrap - Adelie      32.4 67.5 339     -127      191   0.480  0.8807
Gentoo - Adelie     1375.4 56.1 339     1243     1508  24.495 <0.0001
Gentoo - Chinstrap    1342.9 69.9 339     1178     1507  19.224 <0.0001
```

Confidence level used: 0.95


Conf-level adjustment: tukey method for comparing a family of 3 estimates

P value adjustment: tukey method for comparing a family of 3 estimates

Ve výstupu sledujeme řádky jednotlivých dvojic. Sloupec *estimate* je odhadnutý rozdíl průměrů, *lower.CL* a *upper.CL* jsou meze simultánního intervalu a *p.value* je p-hodnota upravená pro společnou rodinu porovnání. Poznámky pod výstupem potvrzují, že Tukeyho korekce byla použita pro intervaly i p-hodnoty. Přehledněji si stejné hodnoty uspořádáme do tabulky.

Porovnání	Rozdíl (g)	Dolní mez (g)	Horní mez (g)	Upravená p-hodnota
Chinstrap minus Adélie	32.4	-126.5	191.4	0.881
Gentoo minus Adélie	1375.4	1243.2	1507.5	<0.001
Gentoo minus Chinstrap	1342.9	1178.5	1507.4	<0.001

Tabulka zachovává hlavní čísla z výstupu `summary(post_hoc_druhy)`. Teď je převedeme do grafu: bod ukáže odhad rozdílu, vodorovná úsečka jeho simultánní interval a svislá čára nulu.



Obrázek 21: Tři Tukeyho post-hoc rozdíly a simultánní 95% intervaly. Nula znamená stejné průměry dané dvojice.

Rozdíl Chinstrap minus Adélie je 32.4 g a simultánní interval od -126.5 do 191.4 g protíná nulu. Data tedy tento malý rozdíl neodlišují od nuly. Oba rozdíly zahrnující Gentoo jsou přibližně 1375 až 1343 g a jejich intervaly leží celé nad nulou.

Celková a párová otázka dávají různé informace

Analýza rozptylu ukázala, že všechny tři průměry nejsou stejné. Párová porovnání upřesnila proč: Gentoo se zřetelně liší od obou dalších druhů, zatímco Adélie a Chinstrap mají v tomto výběru velmi podobné průměrné hmotnosti.

14 Popisuje model data rozumně?

Výsledek testu není konec analýzy. Stejně jako u přímky zkontrolujeme diagnostiku modelu. U kategoriálního prediktoru má graf residuí proti odhadnutým hodnotám zvláštní, ale očekávaný tvar: protože model odhaduje tři skupinové průměry, body tvoří tři svislé pásy.


Co od diagnostiky potřebujeme

Test předpokládá nezávislá pozorování, přibližně srovnatelnou variabilitu residuí ve skupinách a přibližně normální tvar residuí. Graf residuí proti odhadnutým hodnotám pomáhá posoudit srovnatelnost rozptylu; Q-Q graf pomáhá posoudit tvar rozdělení. Nezávislost však z těchto grafů nepoznáme — musíme ji zdůvodnit způsobem, jakým byla pozorování získána.

Doplňující: co když se skupiny liší variabilitou?


Rozdílný rozptyl residuí neznamená, že rozdíl průměrů zmizel. Znamená, že běžný model se společným residuálním rozptylem nemusí správně vyjádřit nejistotu tohoto rozdílu. Nápovědou může být výrazně širší pás residuí u jednoho druhu nebo skupinové rozdělení s velmi odlišnou šířkou.

Pro dvě skupiny už jsme viděli Welchův t-test, který společný rozptyl nevyžaduje. Pro více skupin existuje Welchova ANOVA a v modelovém rámci také další způsoby výpočtu odolnější nejistoty. Volba řešení závisí na otázce, velikosti skupin a tvaru dat; diagnostický graf proto nemá sloužit jako automatický příkaz k transformaci nebo mazání pozorování.



Obrázek 22: Residua proti odhadnutým hodnotám. Tři svislé pásy odpovídají třem skupinovým průměrům a jsou vlastností tohoto modelu, ne samy o sobě závadou.

Ve všech třech pásích jsou residua rozptýlena kolem nuly. Rozsah není dokonale totožný, ale žádná skupina nevytváří dramaticky odlišný vějíř a žádný jednotlivý bod zjevně neurčuje celý výsledek.



Obrázek 23: Q–Q graf residuí. Body převážně sledují referenční přímku; menší odchylky na koncích jsou u reálných dat běžné.

Q–Q graf porovnává seřazená residua s hodnotami očekávanými při přibližně normálním tvaru. Body většinou sledují přímku. Model proto pro úvodní srovnání skupin nevykazuje problém, který by převzal hlavní biologický příběh. To neznamená, že jsou předpoklady „dokázané“; znamená to, že grafy neukazují zásadní rozpor.

15 Co jednoduchý model neoddělil

Rozdíly mezi druhy jsou v těchto datech **asociace**. Jedinci nebyli náhodně přiřazeni ke druhům a druhy nebyly na ostrovech zastoupeny stejně.

Druh	Biscoe	Dream	Torgersen
tučňák kroužkový (Adélie)	44	56	51
tučňák uzdičkový (Chinstrap)	0	68	0
tučňák oslí (Gentoo)	123	0	0

Všichni tučňáci uzdičkoví v tomto výběru pocházejí z ostrova Dream a všichni tučňáci oslí z ostrova Biscoe. Adélie byli měřeni na všech třech ostrovech. Jednoduchý model proto neumí oddělit druh od prostředí ostrova.

Pohlaví také souvisí s hmotností. Následující graf tuto strukturu pouze zviditelňuje; stále nefitujeme model s více prediktory.



Obrázek 24: Hmotnosti tří druhů rozlišené podle zaznamenaného pohlaví. Šedé body mají pohlaví nezaznamenané.

Otázka pro následující lekci

Změnil by se odhad rozdílu mezi druhy, kdybychom porovnávali jedince stejného pohlaví nebo současně zohlednili ostrov? Odpověď vyžaduje model s více prediktory, který budeme stavět příště.

16 Co tedy můžeme říct o tučňácích?

Správný závěr nezačíná p-hodnotou. Nejprve uvedeme velikost rozdílů, potom jejich nejistotu a teprve pak testovou informaci a omezení studie.

Sestavte závěr z pěti částí

Napište krátký odstavec v pořadí: biologická otázka → rozdíly v gramech → intervaly → celkový a párový test → omezení zobecnění a kauzality.

Příklad opatrného závěru

V souboru 342 dospělých tučňáků byla celková analýza rozptylu obtížně slučitelná s hypotézou tří stejných průměrů ($F(2, 339) = 343.63$; p-hodnota $< 0,001$). V navazujících Tukeyho

post-hoc porovnání byla průměrná hmotnost Gentoo přibližně o 1375 g vyšší než u Adélie a o 1343 g vyšší než u Chinstrap; simultánní 95% intervaly pro oba rozdíly ležely celé nad nulou. Průměry Adélie a Chinstrap se lišily pouze o 32 g a jejich interval od -127 do 191 g zahrnoval nulu.

17 Propojení s celým dosavadním kurzem

Dřívější myšlenka	Jak se objevila v této lekci
Typ proměnné určuje vhodný popis	Numerickou hmotnost jsme vysvětlovali kategoriálním druhem.
Graf předchází modelu	Nejdříve jsme viděli jednotlivce, překryv a variabilitu, až potom průměry a koeficienty.
$y_i = \hat{y}_i + e_i$	Odhadnuté hodnoty se změnily z bodů na přímce na skupinové průměry; residua zůstala vzdálenostmi od odhadu.
Efekt a jeho nejistota jsou dvě informace	Rozdíly v gramech jsme doplnili intervaly spolehlivosti.
Test je otázka o parametru	Dvoustupinový t-test se stal testem koeficientu a analýza rozptylu celkovou otázkou o všech skupinových průměrech.
Závěr není jen p-hodnota	Výsledek spojil velikost rozdílů, intervaly, testy, diagnostiku a omezení studie.

18 Co si odnést

- Kategoriaální prediktor nemění lineární model v úplně jinou metodu; mění způsob, jakým model vytváří odhadnuté hodnoty.
- Ve dvouskupinovém modelu je intercept průměr referenční skupiny a druhý koeficient rozdíl druhé skupiny vůči referenci.
- Odhadnuté hodnoty jsou skupinové průměry a residua jsou vzdálenosti jednotlivých pozorování od jejich skupinového průměru.
- Rozdíl mezi průměry posuzujeme vzhledem k variabilitě uvnitř skupin. Odtud pochází logika analýzy rozptylu.
- T-test se společným rozptylem je dvouskupinový lineární model zapsaný jiným způsobem.
- Celkový výsledek analýzy rozptylu říká, zda jsou všechny průměry slučitelné se stejnou hodnotou; neříká automaticky, která dvojice se liší.
- Post-hoc porovnání následují až po celkovém testu a musí zohlednit, že zkoumáme více dvojic současně.
- Biologický závěr začíná rozdíly v gramech a jejich nejistotou a končí předpoklady a omezeními studie.

Slovníček pojmů

Pojmy použité v těchto materiálech a jejich definice. Úplný průběžně aktualizovaný slovníček je dostupný také [online](#).

Interaktivní slovníček je dostupný online: <https://cuni-natur-biostatistics.github.io/slovník/>