

Když prediktor není číslo

Od rozdílu průměrů k analýze rozptylu

9. října 2026

Obsah

1 Úvod	2
2 Výsledky učení	2
3 Data: jeden řádek je jeden změřený tučňák	2
4 Hmotnosti tučňáků kroužkových a oslíků	7
4.1 Průměr a směrodatná odchylka každého druhu	9
5 Rozdíl průměrů	10
5.1 Stejný rozdíl, jiná variabilita	11
6 Stejný lineární model, jiný prediktor	13
6.1 Připomenutí: přímka pro délku ploutve a hmotnost	13
6.2 Kde je intercept?	14
6.3 Kde je sklon?	15
6.4 Kde je residuum?	16
6.5 Stejné koeficienty ve výstupu R	17
7 Lineární model s kategoriální proměnnou	17
7.1 Rovnice se dvěma hodnotami přepínače	19
8 Dvouskupinový model v R	20
9 Odhadnuté hodnoty a residua nezmizely	24
10 Jak velký a přesný je rozdíl dvou druhů?	27
10.1 Je rozdíl slučitelný s nulou?	29
10.2 Historická poznámka: dvouvýběrový t-test v literatuře	31
11 Tři druhy, stejná formule	34
11.1 Tři skupiny potřebují dva přepínače	35
12 Popisuje model data rozumně?	36
13 Jedna celková otázka: analýza rozptylu	38
13.1 Jeden společný průměr proti třem skupinovým průměrům	39
13.2 Co porovnává F-statistika	40
13.3 Jak číst tabulku <code>anova()</code> řádek po řádku	42
13.4 Jak se z F-statistiky stane p-hodnota	42
14 Post-hoc: které dvojice se liší?	43
15 Co jednoduchý model neoddělil	47
16 Co tedy můžeme říct o tučňácích?	48
17 Co bude následovat dál	49

18 Shrnutí	49
18.1 Jak lekce navazuje na předchozí	49
18.2 Závěrečná otázka	50
Slovníček pojmů	50

1 Úvod

Hlavní biologická otázka

Liší se průměrná hmotnost těla mezi druhy tučňáků?

V předchozí lekci jsme převáděli biologické tvrzení na nulovou hypotézu o koeficientu známého modelu. Prediktorem byla numerická proměnná (zeměpisná šířka) a otázka zněla, zda je sklon slučitelný s nulou. V této lekci bude prediktorem kategoriální proměnná: druh tučňáka.

Způsob uvažování zůstává stejný. Výsledek začíná jednotlivými pozorováními, pokračuje rozdílem v gramech a jeho nejistotou a testová otázka jej pouze doplňuje.


2 Výsledky učení

Po prostudování této lekce dokážete:

- fitovat `lm(y ~ skupina)` pro dvě i více skupin a přechít jeho koeficienty;
- interpretovat intercept jako průměr referenční skupiny a ostatní koeficienty jako rozdíly vůči této skupině;
- vysvětlit dvouvýběrový t-test a analýzu rozptylu (ANOVA) jako otázky položené lineárnímu modelu;
- rozlišit celkový F-test od post-hoc porovnání dvojic a rozhodnout, kdy párová porovnání dávají smysl;
- napsat závěr v biologicky smysluplných jednotkách: rozdíl, jeho nejistota, test a omezení studie.

3 Data: jeden řádek je jeden změřený tučňák

Data obsahují tělesná měření dospělých tučňáků tří druhů z Palmerova souostroví v Antarktidě. Jeden řádek představuje jednoho změřeného jedince. Naše odezva je hmotnost těla v gramech a kategoriálním prediktorem je druh.



Obrázek 1: Druhy tučňáků v datasetu Palmer Penguins a barvy, které pro ně budeme používat.
Ilustrace: Allison Horst.

Stejně jako v lekci o grafech a typech proměnných budeme tučňáka kroužkového (Adélie) zobrazovat oranžově, tučňáka uzdičkového (Chinstrap) fialově a tučňáka oslího (Gentoo) modrozeleně.

Tabulku načteme a známými funkcemi zjistíme, jaké hodnoty a datové typy obsahuje. `str()` ukáže strukturu tabulky a typ každé proměnné, `summary()` základní souhrny sloupců a `colSums(is.na())` počet chybějících hodnot v každém sloupci.

```
# Načteme připravenou tabulku s jedním řádkem na tučňáka
data_tucnaci <-
  read.csv(
    file = "data/palmer_penguins.csv",
    na.strings = c("", "NA")
  )

# Zkontrolujeme strukturu a datové typy
str(data_tucnaci)
```

```
'data.frame':  344 obs. of  8 variables:
 $ druh          : chr  "Adelie" "Adelie" "Adelie" "Adelie" ...
 $ ostrov        : chr  "Torgersen" "Torgersen" "Torgersen" "Torgersen" ...
 $ delka_zobaku_mm : num  39.1 39.5 40.3 NA 36.7 39.3 38.9 39.2 34.1 42 ...
 $ hloubka_zobaku_mm: num  18.7 17.4 18 NA 19.3 20.6 17.8 19.6 18.1 20.2 ...
 $ delka_kridla_mm : int   181 186 195 NA 193 190 181 195 193 190 ...
 $ hmotnost_tela_g : int  3750 3800 3250 NA 3450 3650 3625 4675 3475 4250 ...
```

```
$ pohlavi      : chr "male" "female" "female" NA ...
$ rok         : int  2007 2007 2007 2007 2007 2007 2007 2007 2007 2007 ...
```

```
# Prohlédneme si souhrny hodnot
summary(data_tucnaci)
```

```
      druh      ostrov  delka_zobaku_mm hlobka_zobaku_mm
Length:344   Length:344      Min.   :32.10      Min.   :13.10
Class :character Class :character 1st Qu.:39.23      1st Qu.:15.60
Mode  :character Mode  :character Median :44.45      Median :17.30
                        Mean   :43.92      Mean   :17.15
                        3rd Qu.:48.50      3rd Qu.:18.70
                        Max.   :59.60      Max.   :21.50
                        NA's   :2         NA's   :2

delka_kridla_mm hmotnost_tela_g  pohlavi      rok
Min.   :172.0   Min.   :2700   Length:344   Min.   :2007
1st Qu.:190.0   1st Qu.:3550   Class :character 1st Qu.:2007
Median :197.0   Median :4050   Mode  :character Median :2008
Mean   :200.9   Mean   :4202                      Mean   :2008
3rd Qu.:213.0   3rd Qu.:4750                      3rd Qu.:2009
Max.   :231.0   Max.   :6300                      Max.   :2009
NA's   :2       NA's   :2
```

```
# Spočítáme chybějící hodnoty v každém sloupci
colSums(x = is.na(x = data_tucnaci))
```

```
      druh      ostrov  delka_zobaku_mm hlobka_zobaku_mm
      0          0          2          2
delka_kridla_mm hmotnost_tela_g      pohlavi      rok
      2          2          11          0
```

Tabulka má 344 řádků. Sloupec `druh` je zatím text (`chr`) a u 2 tučňáků chybí hmotnost. Hmotnost se pohybuje od 2 700 do 6 300 g, což jsou u dospělých tučňáků těchto druhů věrohodné hodnoty.

Model hmotnosti nemůže použít řádek, ve kterém hmotnost chybí: bez naměřené odezvy nelze spočítat residuum. Ponecháme proto jen tučňáky se změřenou hmotností. Ostatní chybějící položky (například pohlaví) zatím nevadí, protože je v modelu nepoužíváme. Sloupec `druh` zároveň převedeme na **faktor**, tedy kategoriální proměnnou s pevně daným pořadím úrovní. Toto pořadí bude později důležité pro čtení koeficientů.

```
# Ponecháme jen tučňáky se změřenou hmotností
data_tucnaci <-
  data_tucnaci[
    !is.na(data_tucnaci$hmotnost_tela_g),
  ]

# Druh převedeme na faktor s pevným pořadím úrovní
data_tucnaci$druh <-
  factor(
    x = data_tucnaci$druh,
    levels = c("Adelie", "Chinstrap", "Gentoo")
  )

# Ověříme počet ponechaných řádků a úrovně druhu
nrow(x = data_tucnaci)
```

```
[1] 342
```

```
levels(x = data_tucnaci$druh)
```

```
[1] "Adelie"      "Chinstrap" "Gentoo"
```

Druh	Ostrov	Hmotnost těla (g)	Pohlaví	Rok
Adelie	Torgersen	3750	male	2007
Adelie	Torgersen	3800	female	2007
Adelie	Torgersen	3250	female	2007
Adelie	Torgersen	NA	NA	2007
Adelie	Torgersen	3450	female	2007
Adelie	Torgersen	3650	male	2007

Doplňující: získání a příprava dat

Pro průchod lekcí stačí připravený soubor `data/palmer_penguins.csv`. Ten záměrně zachovává všech 344 řádků, aby byly chybějící hodnoty při prvním prohlédnutí viditelné. Pokud si ale chcete celý postup zopakovat, následující kód provede celý sled kroků: **získá data** → **vybere a přejmenuje sloupce** → **připraví je pro model hmotnosti** → **uloží vlastní pracovní kopii**.

Kód vynechá řádky bez hmotnosti hned po stažení, takže vlastní kopie bude mít jen 342 řádků. Druh v ní rovnou uloží jako faktor se stejným pořadím úrovní jako výše. Tento blok můžete přeskočit; další příklady používají tabulku `data_tucnaci` připravenou výše.

```
# Tento příkaz stačí spustit pouze jednou
# install.packages("palmerpenguins")

# Získáme data a prohlédneme chybějící hmotnosti
data_puvodni <- palmerpenguins::penguins
sum(is.na(data_puvodni$body_mass_g))
data_puvodni <- data_puvodni[!is.na(data_puvodni$body_mass_g), ]

# Vybereme, přejmenujeme a upravíme sloupce pro lekci
data_tucnaci <-
  data.frame(
    druh = factor(
      x = data_puvodni$species,
      levels = c("Adelie", "Chinstrap", "Gentoo")
    ),
    ostrov = as.character(data_puvodni$island),
    delka_zobaku_mm = data_puvodni$bill_length_mm,
    hloubka_zobaku_mm = data_puvodni$bill_depth_mm,
    delka_kridla_mm = data_puvodni$flipper_length_mm,
    hmotnost_tela_g = data_puvodni$body_mass_g,
    pohlavi = as.character(data_puvodni$sex),
    rok = data_puvodni$year
  )

# Uložíme si zpracovanou tabulku pro další práci
write.csv(
  x = data_tucnaci,
  file = "data/palmer_penguins_vlastni_kopie.csv",
  row.names = FALSE,
  na = ""
)
```

Balíček `palmerpenguins` obsahuje kopii původních tabulek z Environmental Data Initiative. [Dokumentace balíčku palmerpenguins](#) uvádí také cestu k neupraveným archivním souborům. Měření pocházejí z výzkumu tučňáků rodu *Pygoscelis* v letech 2007–2009. Data shromáždila Kristen Gorman ve spolupráci s Palmer Station Long Term Ecological Research a byla zveřejněna pod licencí CC0. Připravený soubor a jeho přesná provenance jsou popsány v [data/README.md](#); biologickou studii uvádějí Gorman, Williams a Fraser (2014), DOI: [10.1371/journal.pone.0090081](#).

4 Hmotnosti tučňáků kroužkových a oslích

Pro první srovnání ponecháme jen dva druhy: tučňáka kroužkového (Adélie) a tučňáka oslího (Gentoo). V prvním grafu jsou jejich hmotnosti smíchané dohromady. Každý bod představuje jedno pozorování, tedy jednoho změřeného jedince.



Obrázek 2: Hmotnosti tučňáků dvou druhů předtím, než použijeme informaci o druhu. Všechny body jsou záměrně šedé.

Bez další proměnné umíme popsat jen tento společný soubor. V lekci o popisu jedné proměnné jsme k tomu používali počet pozorování, minimum, maximum, průměr, medián a mezikvartilové rozpětí (IQR). Stejně souhrny nyní spočítáme v R:

```
# Pro první pohled vybereme dva druhy, ale zatím je nesrovnáváme
data_dva_druhy <-
  data_tucnaci[
    data_tucnaci$druh %in% c("Adelie", "Gentoo"),
  ]
data_dva_druhy$druh <- droplevels(data_dva_druhy$druh)
```

```
# Připomeneme si známé souhrny pro všechny hmotnosti dohromady
c(
  pocet = length(data_dva_druhy$hmotnost_tela_g),
  prumer = mean(data_dva_druhy$hmotnost_tela_g),
  median = median(data_dva_druhy$hmotnost_tela_g),
  minimum = min(data_dva_druhy$hmotnost_tela_g),
  maximum = max(data_dva_druhy$hmotnost_tela_g),
  IQR = IQR(data_dva_druhy$hmotnost_tela_g)
)
```

pocet	prumer	median	minimum	maximum	IQR
274.000	4318.066	4262.500	2850.000	6300.000	1350.000

Společný průměr 4 318,1 g shrnuje střed šedého oblaku, ale zakrývá možnost, že se v něm mísí odlišné skupiny. Tuto možnost prověří proměnná `druh`.

Proměnná `druh` je kategoriální: její hodnoty nejsou měření na číselné škále, ale názvy kategorií. Funkce `table()` ukáže, kolik řádků (jedinců) patří do každé kategorie:

```
table(data_tucnaci$druh)
```

Adelie	Chinstrap	Gentoo
151	68	123


V celé tabulce jsou tři druhy. Pro první model ponecháváme pouze Adélie a Gentoo, které jsme vybrali do objektu `data_dva_druhy`.

Co by tvrdila nulová hypotéza?

V předchozí lekci jsme testovali nulovou hypotézu o koeficientu modelu. Zkuste vyslovit nulovou hypotézu pro průměrnou hmotnost Adélie a Gentoo. Jak by podle ní vypadal graf, ve kterém body obarvíme podle druhu?

Možná odpověď

Nulová hypotéza tvrdí, že průměrná hmotnost obou druhů je v širší populaci stejná: rozdíl průměrů je 0 g. Body obou druhů by pak ležely kolem stejné výšky. Jednotlivci by se stále lišili, ale žádný druh by systematicky neležel výše.




Obrázek 3: Stejná měření po přidání kategoriální proměnné druh. Barva i vodorovná poloha nyní ukazují příslušnost ke skupině.

Po rozdělení vidíme silný posun: body tučňáků oslích leží převážně výše. Zároveň se hodnoty uvnitř každého druhu liší a oba soubory se částečně překrývají. Druh nám tedy pomohl odhalit strukturu, kterou šedý graf skrýval.

4.1 Průměr a směrodatná odchylka každého druhu

Druh	Počet jedinců	Průměr (g)	SD (g)
tučňák kroužkový (Adélie)	151	3700,7	458,6
tučňák oslí (Gentoo)	123	5076,0	504,1

Průměr shrnuje polohu jedné skupiny, ale neříká, jak se liší jednotlivci uvnitř ní. Proto vedle něj zobrazíme směrodatnou odchylku (SD) i všechny body. Svislá úsečka kolem průměru sahá od průměru minus jedna SD po průměr plus jedna SD.




Obrázek 4: Body jsou jednotliví tučňáci, silné vodorovné úsečky jsou průměry a tenké svislé úsečky ukazují průměr $\pm$ 1 SD.

Průměr tučňáků oslích je o 1 375,4 g vyšší než průměr tučňáků kroužkových. To je hlavní věcný rozdíl, který bude náš model popisovat.

5 Rozdíl průměrů

Dva průměry se mohou lišit o stejnou hodnotu, ale síla informace závisí také na variabilitě uvnitř skupin. Následující graf proto skrývá jednotlivé body a ponechává pouze tři součásti: dva průměry, jejich rozdíl a SD každé skupiny.




Obrázek 5: Silné vodorovné úsečky jsou průměry, svislé úsečky ukazují ± 1 SD a závorka vpravo měří rozdíl mezi průměry. Celkový rozsah dat zde záměrně nezobrazujeme.

Svislá závorka měří systematický rozdíl, který chceme vysvětlit druhem. Úsečky SD připomínají, že každý průměr zastupuje celý oblak různých jedinců. Rozdíl průměrů proto nikdy nebudeme číst bez informace o variabilitě kolem nich.

5.1 Stejný rozdíl, jiná variabilita

Následující obrázek není další výběr tučňáků. Je to záměrně zjednodušený myšlenkový pokus se dvěma vymyšlenými skupinami A a B po deseti jedincích. Ve všech třech panelech se průměry skupin liší o stejných 1 000 g; panely se liší jen tím, jak daleko jsou jedinci rozptýleni kolem průměru své skupiny.



Obrázek 6: Myšlenkový pokus se dvěma vymyšlenými skupinami A a B: rozdíl mezi průměry (vodorovné úsečky) je ve všech třech panelech stejný, směrodatná odchylka uvnitř skupin zleva doprava roste.

Kde je rozdíl nejpřesvědčivější?

Rozdíl průměrů je ve všech panelech stejný. Ve kterém panelu bychom nejsnáze odlišili systematický rozdíl mezi skupinami od běžných rozdílů mezi jedinci? A ve kterém nejhůře?

Možná odpověď

Nejsnáze v levém panelu: skupiny se téměř nepřekrývají a rozdíl průměrů je mnohem větší než typická odchylka jedince od průměru jeho skupiny. Nejhůře v pravém panelu: rozdíl průměrů je zde stejně velký jako směrodatná odchylka uvnitř skupin a skupiny se výrazně překrývají. Stejný rozdíl průměrů tak může být přesvědčivý i sotva rozeznatelný.

Rozdíl průměrů tedy nečteme izolovaně. Posuzujeme jej vzhledem k variabilitě, která zůstává kolem skupinových průměrů. Z tohoto porovnání vychází také název metody analýza rozptylu, ke které se v této lekci dostaneme: porovnává variabilitu zachycenou rozdílnými skupinovými průměry s residuální variabilitou uvnitř skupin.


Rozdíl hmotností zatím pouze popisujeme. Abychom k němu mohli připojit nejistotu a test, **fitujeme lineární model**: odezvou bude hmotnost těla a prediktorem druh. Před vložením kategoriální proměnné do známé formule si připomeneme, jak model pracoval s numerickým prediktorem.

6 Stejný lineární model, jiný prediktor

6.1 Připomenutí: přímka pro délku ploutve a hmotnost

V lekci o vztazích dvou proměnných jsme u tučňáků kreslili bodový graf délky ploutve a tělesné hmotnosti; v lekci o lineárním modelu jsme podobný vztah popsali přímkou. Přímku si připomeneme právě na tučňácích: délka ploutve (sloupec `delka_kridla_mm`) bude prediktorem a hmotnost těla odezvou.

Každý bod je jeden tučňák. Délka ploutve určuje jeho vodorovnou polohu a fialová přímka ukazuje, jakou hmotnost model pro tuto délku odhaduje.




Obrázek 7: Pozorované délky ploutve a hmotnosti tučňáků s odhadnutou přímkou. Každá hodnota numerického prediktoru vybírá jedno místo na přímce.

6.2 Kde je intercept?

V lekci o lineárním modelu jsme intercept a sklon psali jako a a b . V lekcích o nejistotě a testování hypotéz jsme pro stejné koeficienty používali řecké písmeno β (beta): β_0 je intercept a β_1 sklon v širší populaci. Strážka označuje odhad z našich dat, takže $\hat{\beta}_0$ je totéž co dřívější a a $\hat{\beta}_1$ totéž co b .


Intercept $\hat{\beta}_0$ je odhadnutá hmotnost tučňáka s ploutví dlouhou 0 mm. Nula leží daleko mimo pozorované délky ploutví (172–231 mm), proto plnou přímku prodloužíme čárkovaně až k nule. Vychází $\hat{\beta}_0 = -5\,781$ g, tedy záporná hmotnost. Intercept umíme v rovnici vypočítat, ale tady nemá biologický smysl: je to extrapolace daleko za naše data.



Obrázek 8: Intercept je výška přímky při hodnotě prediktoru 0. Čárkovaná část upozorňuje, že mezi nulou a nejkratší pozorovanou ploutví nemáme žádná data.

6.3 Kde je sklon?


Sklon $\hat{\beta}_1$ je změna odhadnuté hmotnosti při prodloužení ploutve o 1 mm. Jeden milimetr by byl v grafu téměř neviditelný, proto zvýrazníme prodloužení o 10 mm. Odpovídající změna výšky přímky je $10 \cdot \hat{\beta}_1 = 497$ g.



Obrázek 9: Sklon převádí změnu prediktoru na změnu odhadnuté hodnoty. Kvůli čitelnosti je zobrazena změna při prodloužení ploutve o 10 mm.

6.4 Kde je residuum?

Residuum je svislá vzdálenost naměřené hodnoty od hodnoty na přímce. U zvýrazněného tučňáka s ploutví dlouhou 202 mm porovnáme naměřenou hmotnost 3 400 g s odhadem modelu 4 256 g. Residuum je jejich rozdíl, -856 g.



Obrázek 10: Residuum jednoho pozorování je svislá vzdálenost mezi naměřenou hodnotou (plný oranžový bod) a odhadnutou hodnotou na přímce (prázdný fialový bod).

6.5 Stejné koeficienty ve výstupu R

Funkce `lm()` vrátí stejné dva koeficienty, které jsme v grafech hledali odděleně.

```
# Odhadneme přímku pro hmotnost podle délky ploutve
mod_ploutev <-
  lm(
    formula = hmotnost_tela_g ~ delka_kridla_mm,
    data = data_tucnaci
  )

# Zobrazíme odhadnutý intercept a sklon
coef(object = mod_ploutev)
```

```
(Intercept) delka_kridla_mm
-5780.83136      49.68557
```

Řádek `(Intercept)` je **intercept**, tedy výška přímky při délce ploutve 0 mm. Řádek `delka_kridla_mm` je **sklon**, tedy změna odhadnuté hmotnosti při prodloužení ploutve o 1 mm. Slovy:

$$\text{odhadnutá hmotnost} = \text{intercept} + \text{sklon} \cdot \text{délka ploutve}.$$

Pro tučňáka s ploutví dlouhou 190 mm:

$$\text{odhadnutá hmotnost} = -5\,780,8 + 49,69 \cdot 190 = 3\,659,4 \text{ g}.$$

Obecně, kde x_i je délka ploutve tučňáka i , $\hat{y}_i$ jeho odhadnutá hmotnost, $\hat{\beta}_0$ intercept a $\hat{\beta}_1$ sklon:

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i.$$

Residuum dál měří svislou vzdálenost konkrétního pozorování od této přímky. U numerického prediktoru jsme tedy naměřenou hodnotu rozdělili na hodnotu odhadnutou modelem a residuum:

$$\text{naměřená hodnota} = \text{odhadnutá hodnota} + \text{residuum},$$

$$y_i = \hat{y}_i + e_i = \hat{\beta}_0 + \hat{\beta}_1 x_i + e_i.$$

Číslo x_i určovalo polohu pozorování na vodorovné ose a výraz $\hat{\beta}_0 + \hat{\beta}_1 x_i$ vybral odpovídající výšku na přímce. Prediktor druh ale obsahuje názvy, ne čísla. Aby mohl vstoupit do stejného výpočtu, model si z něj vytvoří číselnou proměnnou.


7 Lineární model s kategoriální proměnnou

Vraťme se k hlavní biologické otázce: **liši se průměrná hmotnost Adélie a Gentoo?** Odezvou je stále hmotnost těla v gramech. Místo numerické délky ploutve ale modelu předáváme název druhu.

Lineární model potřebuje způsob, jak dvě kategorie vložit do rovnice. Pro dva druhy stačí binární proměnná „**je Gentoo?**“: hodnota 0 znamená „ne“, tedy Adélie, a hodnota 1 znamená „ano“, tedy Gentoo. Protože takovou proměnnou zapínáme a vypínáme, budeme jí říkat **přepínač**. Nejde o nové biologické měření ani pořadí druhů. Je to pouze číselný zápis příslušnosti ke skupině. Tabulka jej ukazuje jako nový sloupec vedle dvou skutečných pozorování.

Druh	Naměřená hmotnost (g)	je Gentoo?
tučňák kroužkový (Adélie)	3750	0
tučňák oslí (Gentoo)	4500	1

V následujícím grafu tvoří stejná proměnná vodorovnou osu. Model stále dostává přesně hodnotu 0 nebo 1. Jednotlivé body v každé skupině pouze nepatrně posuneme doleva a doprava, aby se navzájem nepřekrývaly; tento zobrazovací posun nevytváří nové hodnoty prediktoru. Vodorovné úsečky jsou dvě odhadnuté hodnoty a tečkované svislice jsou vzdálenosti jednotlivých měření od těchto odhadů.



Obrázek 11: Kategorie druhu zapsaná binární proměnnou 0/1. Model přiřadí všem jedincům s hodnotou 0 průměr Adélie a všem jedincům s hodnotou 1 průměr Gentoo. Body jsou jen kvůli překryvu mírně posunuty do stran; tečkované úsečky jsou residua.

Nula a jednička nejsou další biologická měření a neříkají, že jeden druh je „vyšší“ nebo „lepší“. Jsou jen jazykem, kterým modelu sdělíme příslušnost ke skupině. Stejně jako u numerického prediktoru zůstává odhadnutá hodnota ve tvaru intercept plus koeficient krát hodnota prediktoru.

7.1 Rovnice se dvěma hodnotami přepínače

Intercept je v tomto modelu průměrná hmotnost referenčního druhu Adélie. **Druhý koeficient** je rozdíl mezi průměrem Gentoo a průměrem Adélie. U numerického prediktoru byl druhý koeficient sklon; zde má nový význam skupinového rozdílu. Slovy:

$$\begin{aligned} \text{odhadnutá hmotnost těla} &= \text{průměrná hmotnost druhu Adélie} \\ &+ \text{rozdíl Gentoo vůči Adélie} \cdot \text{„je Gentoo?“} . \end{aligned}$$

Pro Adélie má přepínač hodnotu 0:

$$\begin{aligned}\text{odhadnutá hmotnost Adélie} &= 3\,700,7 + 1\,375,4 \cdot 0 \\ &= 3\,700,7 \text{ g} .\end{aligned}$$

Pro Gentoo má přepínač hodnotu 1:

$$\begin{aligned}\text{odhadnutá hmotnost Gentoo} &= 3\,700,7 + 1\,375,4 \cdot 1 \\ &= 5\,076,0 \text{ g} .\end{aligned}$$

Obecně zapíšeme stejný vztah se symboly, které už známe. Symbol x_i je nyní přepínač „je Gentoo?“ pro tučňáka i (0 nebo 1), $\hat{\beta}_0$ odhadnutý průměr Adélie a $\hat{\beta}_1$ odhadnutý rozdíl Gentoo minus Adélie:

$$\begin{aligned}\hat{y}_i &= \hat{\beta}_0 + \hat{\beta}_1 x_i, \\ y_i &= \hat{\beta}_0 + \hat{\beta}_1 x_i + e_i.\end{aligned}$$

Zápis se od numerického prediktoru nezměnil. Změnil se význam x_i a tím i význam koeficientu $\hat{\beta}_1$: už nepopisuje změnu při zvýšení prediktoru o jednu měrnou jednotku, ale rozdíl jedné skupiny vůči referenční skupině.

Nula a jednička nejsou pořadí druhů

Kdybychom vyměnili referenční druh, změnil by se přepínač, intercept i znaménko koeficientu. Skupinové průměry a biologický obsah dat by však zůstaly stejné. Kódování je jazyk modelu, ne vlastnost tučňáků.

8 Dvouskupinový model v R

V R zůstává funkce `lm()` stejná. Do pravé strany formule vložíme `druh`. R ale musí rozhodnout, vůči kterému druhu bude zapisovat rozdíl. Proto zvolí jednu úroveň faktoru jako **referenční skupinu**.

Ve výchozím kódování používá R jako referenci první úroveň faktoru. Při přípravě dat jsme pořadí nastavili na `Adelie`, `Chinstrap`, `Gentoo`; po ponechání dvou druhů proto zůstane první Adélie. Volba reference je nutná, protože informace „je Adélie?“ a „je Gentoo?“ jsou u dvou druhů navzájem dokonale propojené: známe-li jednu odpověď, druhou už dopočítáme. Model proto použije jeden společný základ – intercept reference – a jeden rozdíl druhé skupiny vůči němu.

```
# Ponecháme dva druhy a odstraníme nevyužitou třetí úroveň
data_dva_druhy <-
  data_tucnaci[
    data_tucnaci$druh %in% c("Adelie", "Gentoo"),
  ]
data_dva_druhy$druh <- droplevels(data_dva_druhy$druh)
```

```
# Zkontrolujeme pořadí úrovní; první je reference
levels(data_dva_druhy$druh)
```

```
[1] "Adelie" "Gentoo"
```

```
# Fitujeme známý lineární model s kategoriálním prediktorem
mod_dva_druhy <-
  lm(
    formula = hmotnost_tela_g ~ druh,
    data = data_dva_druhy
  )

# Prohlédneme si celý známý výstup modelu
summary(mod_dva_druhy)
```

Call:

```
lm(formula = hmotnost_tela_g ~ druh, data = data_dva_druhy)
```

Residuals:

Min	1Q	Median	3Q	Max
-1126.02	-369.50	-26.02	343.00	1223.98

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	3700.66	39.02	94.83	<2e-16 ***
druhGentoo	1375.35	58.24	23.61	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1


Residual standard error: 479.5 on 272 degrees of freedom

Multiple R-squared: 0.6721, Adjusted R-squared: 0.6709

F-statistic: 557.6 on 1 and 272 DF, p-value: < 2.2e-16

Řádek výstupu	Odhad (g)	Biologický význam	Kde číslo vidíme v grafu
(Intercept)	3700,7	průměrná hmotnost Adélie	vzdálenost průměrové úsečky Adélie od nuly
druhGentoo	1375,4	průměr Gentoo minus průměr Adélie	svislá vzdálenost mezi dvěma průměry

Tabulka překládá řádky výstupu do slov. V následujícím grafu jsou stejná dvě čísla umístěna přímo k datům: intercept je výška průměru Adélie od nuly a koeficient `druhGentoo` je vzdálenost od průměru Adélie k průměru Gentoo.



Obrázek 12: Dva koeficienty dvouskupinového modelu přímo v datech. Intercept β_0 je vzdálenost průměrové úsečky Adélie od nuly; koeficient β_1 je rozdíl Gentoo minus Adélie.

Intercept 3 700,7 g je průměr referenční skupiny Adélie. Koeficient `druhGentoo` 1 375,4 g je rozdíl **Gentoo minus Adélie**. Součet obou koeficientů dává 5 076,0 g, tedy průměr Gentoo.

Doplňující: co se změní, když zvolíme jinou referenci?

Referenci můžeme změnit funkcí `relevel()`. Když jako základ zvolíme Gentoo, intercept se stane průměrem Gentoo a rozdílový koeficient bude Adélie minus Gentoo. Odhadnuté skupi-

nové průměry, residua i biologický obsah modelu zůstanou stejné; změní se pouze způsob jejich zápisu.

```
data_reference_gentoo <- data_dva_druhy
data_reference_gentoo$druh <-
  relevel(
    x = data_reference_gentoo$druh,
    ref = "Gentoo"
  )

levels(data_reference_gentoo$druh)
```

```
[1] "Gentoo" "Adelie"
```

```
mod_reference_gentoo <-
  lm(
    formula = hmotnost_tela_g ~ druh,
    data = data_reference_gentoo
  )

coef(mod_reference_gentoo)
```

```
(Intercept)  druhAdelie
 5076.016    -1375.354
```

Při referenci Gentoo je intercept 5 076,0 g a koeficient `druhAdelie` je -1 375,4 g. Součet opět vrátí průměr Adélie 3 700,7 g.

Ve studii s kontrolou nastavte referenci záměrně

Pokud má studie skutečnou kontrolní skupinu, je obvykle nejčitelnější nastavit ji jako referenci. Intercept potom vyjadřuje průměr kontroly a každý léčebný koeficient odpovídá přímo otázce **ošetření minus kontrola**.

```
data_studie$skupina <-
  relevel(
    x = data_studie$skupina,
    ref = "kontrola"
  )
```

```
levels(data_studie$skupina)
```


Tato volba pouze zpřehlední koeficienty. Nevytváří randomizaci, kontrolní podmínku ani kauzální důkaz — ty závisejí na designu studie. Změna reference také nemění odhadnuté skupinové průměry, residua ani celkový test modelu.

Co netestuje řádek interceptu

P-hodnota v řádku interceptu porovnává průměr Adélie s nulovou hmotností. Nulová hmotnost není naše biologická otázka. Otázku rozdílu druhů ve dvouskupinovém modelu najdeme v řádku `druhGentoo`.

9 Odhadnuté hodnoty a residua nezmizely

V modelu s číselným prediktorem měla každá délka ploutve vlastní hodnotu na přímce. V modelu se dvěma skupinami existují jen dvě odhadnuté hodnoty: průměr Adélie a průměr Gentoo. Každý jedinec stejného druhu dostane stejnou odhadnutou hmotnost, ale vlastní residuum.



Obrázek 13: Každý jedinec sdílí odhadnutou hodnotu svého druhu. Body jsou kvůli překryvu mírně posunuty do stran. Tenké svislé úsečky spojují skutečné body s odhadem a jsou tedy residui; jedno residuum je zvýrazněno.

Pro zvýrazněného tučňáka kroužkového (jeho residuum je ze všech Adélie největší) platí slovy:

$$\text{residuum} = \text{naměřená hmotnost} - \text{odhadnutá hmotnost} .$$

Po dosazení čísel ze stejného řádku dat a z výšky průměrové úsečky:

$$\begin{aligned} \text{residuum} &= 4\,775,0 - 3\,700,7 \\ &= 1\,074,3 \text{ g} . \end{aligned}$$

Obecný zápis používá stejné symboly jako u přímky:

$$e_i = y_i - \hat{y}_i .$$

```

# Z modelu získáme odhadnutou hmotnost každého jedince
data_dva_druhy$odhadnuta_hmotnost_g <-
  fitted(mod_dva_druhy)

# Residuum je měření minus odhadnutá hodnota
data_dva_druhy$residuum_g <-
  resid(mod_dva_druhy)

# Zkontrolujeme první řádky obou nových sloupců
head(
  data_dva_druhy[
    , c(
      "druh",
      "hmotnost_tela_g",
      "odhadnuta_hmotnost_g",
      "residuum_g"
    )
  ]
)

```

	druh	hmotnost_tela_g	odhadnuta_hmotnost_g	residuum_g
1	Adelie	3750	3700.662	49.33775
2	Adelie	3800	3700.662	99.33775
3	Adelie	3250	3700.662	-450.66225
5	Adelie	3450	3700.662	-250.66225
6	Adelie	3650	3700.662	-50.66225
7	Adelie	3625	3700.662	-75.66225

Co zůstalo stejné

Lineární model stále rozděluje každou naměřenou hodnotu na systematickou část a residuum. U číselného prediktoru byla systematickou částí přímka; u kategoriálního prediktoru jsou jí skupinové průměry.

10 Jak velký a přesný je rozdíl dvou druhů?

Z dlouhého výstupu `summary()` vytáhneme jen dva odhadnuté koeficienty. Funkce `coef()` je užitečná právě ve chvíli, kdy víme, na které hodnoty se chceme zaměřit:

```
coef(mod_dva_druhy)
```

(Intercept)	druhGentoo
3700.662	1375.354

Koeficient `druhGentoo` odhaduje rozdíl 1 375,4 g. Podobně jako v předchozích dvou lekcích odhad doplníme standardní chybou a 95% intervalem spolehlivosti.

Interval nevzniká jako další nezávislé číslo. Připomeňme si z lekce o nejistotě, jak se vypočítá ze stejného odhadu a standardní chyby. Slovy:

95% interval = odhad rozdílu $\pm$ kritická hodnota $\cdot$ standardní chyba rozdílu .

Po dosazení odhadu, kritické hodnoty (vysvětlené níže) a standardní chyby z řádku `druhGentoo`:

$$95\% \text{ interval} = 1\,375,4 \pm 1,969 \cdot 58,24 = 1\,260,7 \text{ až } 1\,490,0 \text{ g} .$$

Se symboly, kde $\hat{\beta}_1$ je odhadnutý rozdíl Gentoo minus Adélie a $SE(\hat{\beta}_1)$ jeho standardní chyba:

$$95\% \text{ interval} = \hat{\beta}_1 \pm \underbrace{t_{0,975, df}}_{\text{kritická hodnota}} \cdot SE(\hat{\beta}_1).$$

Pro 95% interval necháváme 2,5 % t-rozdělení v každém krajním chvostu. Kritická hodnota proto závisí na zvolené hladině 95 % a na 272 residuálních stupních volnosti; zde je 1,969.

```
# Vezmeme odhad a standardní chybu z řádku druhGentoo
tabulka_koeficientu <- coef(summary(mod_dva_druhy))
odhad_rozdilu <- tabulka_koeficientu["druhGentoo", "Estimate"]
standardni_chyba <- tabulka_koeficientu["druhGentoo", "Std. Error"]

# Kritická hodnota pro 95% interval a residuální stupně volnosti
kriticka_hodnota <-
  qt(
    p = 0.975,
    df = df.residual(mod_dva_druhy)
  )


dolni_mez <- odhad_rozdilu - kriticka_hodnota * standardni_chyba
horni_mez <- odhad_rozdilu + kriticka_hodnota * standardni_chyba

c(dolni_mez = dolni_mez, horni_mez = horni_mez)
```

```
dolni_mez horni_mez
1260.687 1490.021
```

```
# Stejný výpočet pohodlně provede confint()
confint(mod_dva_druhy)["druhGentoo", ]
```

```
2.5 % 97.5 %
1260.687 1490.021
```



Obrázek 14: Odhad rozdílu průměrné hmotnosti Gentoo minus Adélie a jeho 95% interval spolehlivosti. Nula znamená stejné průměry.

Interval sahá od 1 260,7 do 1 490,0 g. Celý leží nad nulou, ale jeho hlavním sdělením není pouze „nula uvnitř / nula vně“. Ukazuje také, jak velký rozdíl je s daty a modelem slučitelný.

10.1 Je rozdíl slučitelný s nulou?

Nulová hypotéza a alternativa mluví o rozdílu průměrných hmotností obou druhů v širší populaci, ze které změření tučňáci pocházejí:

$$H_0 : \text{průměr Gentoo} - \text{průměr Adélie} = 0,$$

$$H_A : \text{průměr Gentoo} - \text{průměr Adélie} \neq 0.$$

Se symboly jde o tvrzení o populačním koeficientu: $H_0 : \beta_1 = 0$ a $H_A : \beta_1 \neq 0$. Pro výpočet si znovu zobrazíme celý výstup modelu. V řádku `druhGentoo` stojí vedle sebe všechny tři hodnoty, které potřebujeme: odhad rozdílu, jeho standardní chyba a vypočtená t-statistika.

```
summary(mod_dva_druhy)
```

Call:

```
lm(formula = hmotnost_tela_g ~ druh, data = data_dva_druhy)
```

Residuals:

Min	1Q	Median	3Q	Max
-1126.02	-369.50	-26.02	343.00	1223.98

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	3700.66	39.02	94.83	<2e-16 ***
druhGentoo	1375.35	58.24	23.61	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 479.5 on 272 degrees of freedom

Multiple R-squared: 0.6721, Adjusted R-squared: 0.6709

F-statistic: 557.6 on 1 and 272 DF, p-value: < 2.2e-16

V řádku `druhGentoo` tedy čteme `Estimate = 1 375,35`, `Std. Error = 58,24` a `t value = 23,61`. Následující rovnice pouze ukazuje, jak R ze dvou prvních sloupců získalo třetí.

Z předchozí lekce známe vztah mezi odhadem, nulovou hodnotou a jeho nejistotou. Slovy:

$$t\text{-statistika} = \frac{\text{odhadnutý rozdíl} - \text{nulový rozdíl}}{\text{standardní chyba rozdílu}}.$$

Po dosazení čísel z řádku `druhGentoo`:

$$\begin{aligned} t &= \frac{1\,375,4 - 0}{58,2} \\ &= 23,61. \end{aligned}$$

Obecně:

$$t = \frac{\hat{\beta}_1 - 0}{\text{SE}(\hat{\beta}_1)}.$$


Stejně jako v předchozí lekci můžeme výsledek umístit do t-rozdělení očekávaného při nulové hypotéze. Musíme ale rozlišit dvě různá čísla:

- **kritické hranice** jsou zde $-1,969$ a $+1,969$. Oddělují prostředních 95 % nulového t-rozdělení od krajních 5 %: v každém chvostu zůstává 2,5 %. Stejnou kladnou kritickou hodnotu jsme použili už při výpočtu 95% intervalu spolehlivosti;

- **pozorovaná t-statistika** je + 23,61. Tu jsme právě vypočítali z řádku `druhGentoo` v `summary()`.

Kritické hranice tedy **nejso** výsledkem našeho testu. Vymezují předem zvolené rozhodovací oblasti pro $\alpha = 0,05$. Náš výsledek $t = +23,61$ leží mnohem dále od nuly. Protože testujeme oboustrannou otázku, sledujeme také stejně vzdálenou zrcadlovou hranici $-23,61$. P-hodnota je součet ploch nulového t-rozdělení za těmito dvěma hranicemi, nikoli plocha za kritickými hodnotami.

Následující graf proto používá dva panely: první zvětší kritické hranice a oblasti o celkové ploše $\alpha = 0,05$; druhý ukáže skutečně pozorované t a jeho zrcadlovou hranici na celé ose.



Obrázek 15: T-rozdělení při nulové hypotéze. Levý panel ukazuje kritické hranice a fialové chvosty o celkové ploše $\alpha = 0,05$. V pravém panelu fialové čáry tyto hranice připomínají, zatímco oranžové pásy označují oblasti za pozorovaným $t = 23,61$ a zrcadlovou hranicí $-23,61$. P-hodnota je plocha pod t-křivkou uvnitř těchto oranžových oblastí.

Pozorovaný rozdíl leží 23,61 standardních chyb nad nulou, takže skutečně pozorovaná t-statistika je + 23,61. Záporná hodnota $-23,61$ nebyla pozorována; je to zrcadlová hranice potřebná pro oboustrannou otázku. Při 272 residuálních stupních volnosti je součet ploch za oběma hranicemi, tedy p-hodnota, $< 0,001$. Za předpokladů modelu jsou data velmi obtížně slučitelná s přesně nulovým rozdílem mezi těmito dvěma druhy. Slovo „za předpokladů“ je důležité: residua tohoto modelu kontrolujeme stejně jako u přímky. Jak to vypadá u kategoriálního prediktoru, ukážeme níže na modelu se třemi druhy; stejné grafy platí i pro dva druhy.

10.2 Historická poznámka: dvouvýběrový t-test v literatuře

Statistické metody se historicky vyučovaly jako soubor samostatně pojmenovaných testů pro různé situace: jeden test pro dva průměry, jiný pro více průměrů, další pro vztah dvou numerických proměnných. Takové názvy byly praktické v době ručních výpočtů a tabulek, a proto zůstávají v učebnicích, člancích i nabídkách statistických programů dodnes.

Mnoho těchto klasických postupů ale můžeme zapsat jako speciální případy jednoho regresního modelu. Dvoustupňový t-test se společným rozptylem používá za stejných předpokladů tentýž odhad rozdílu, standardní chybu, t-statistiku a p-hodnotu jako koeficient `druhGentoo` v našem dvoustupňovém lineárním modelu. Nemusíme se tedy učit nový způsob uvažování: biologickou otázku, odhad, nejistotu i test stále čteme z jednoho modelového rámce.

Název **dvouvýběrový t-test** však budeme potkávat v další literatuře. Následující příklad proto ukazuje, jak známý modelový výsledek přeložit do historického názvu testu a zpět. Nejde o další nesouvisející analýzu. Aby znaménko odpovídalo našemu koeficientu, odečteme Adélie od Gentoo.

Proč tento historický název uvádíme

Když v knize uvidíte dvouvýběrový t-test se společným rozptylem, můžete si jej představit jako lineární model `y ~ skupina` se dvěma úrovněmi. Při čtení výsledku se znovu ptejte na rozdíl průměrů, jeho standardní chybu, t-statistiku a p-hodnotu.

```
# Připravíme hmotnosti obou skupin ve směru Gentoo minus Adélie
vec_gentoo <-
  data_dva_druhy$hmotnost_tela_g[
    data_dva_druhy$druh == "Gentoo"
  ]
vec_adelie <-
  data_dva_druhy$hmotnost_tela_g[
    data_dva_druhy$druh == "Adelie"
  ]

# Test se společným rozptylem odpovídá dvouskupinovému lm()
t.test(
  x = vec_gentoo,
  y = vec_adelie,
  var.equal = TRUE
)
```

Two Sample t-test

```
data:  vec_gentoo and vec_adelie
t = 23.614, df = 272, p-value < 2.2e-16
alternative hypothesis: true difference in means is not equal to 0
95 percent confidence interval:
 1260.687 1490.021
sample estimates:
mean of x mean of y
 5076.016  3700.662
```


Postup	Rozdíl Gentoo – Adélie (g)	t-statistika	df
koeficient v lm()	1375,4	23,61	272
t-test se společným rozptylem	1375,4	23,61	272

Výchozí t.test() v R je Welchův test

Bez argumentu `var.equal = TRUE` používá R Welchův t-test, který nevyžaduje společný rozptyl skupin a může mít jiné stupně volnosti i mírně jiný interval. Není proto pravda, že každý výstup `t.test()` musí být číselně totožný s obyčejným `lm()`. Totožnost v tabulce platí pro stejnou otázku a stejné předpoklady.

11 Tři druhy, stejná formule

Do dat se vrací tučňák uzdičkový (Chinstrap). Do `lm()` nemusíme přidávat nový druh ručně: faktor `druh` už obsahuje všechny tři úrovně.



Obrázek 16: Tři druhy s průměrem ± 1 SD. Svislé závorky ukazují oba rozdíly, které model přímo vyjadřuje vůči referenčnímu druhu Adélie.

Průměry Adélie a Chinstrap leží blízko sebe, zatímco průměr Gentoo je mnohem výše. To je přesně situace, ve které potřebujeme odlišit tři otázky: jak se jednotlivé skupiny liší od reference, zda jsou všechny tři průměry celkově stejné a které konkrétní dvojice chceme porovnat.

```
# Fitujeme stejnou formuli na všech třech druzích
mod_tri_druhy <-
  lm(
    formula = hmotnost_tela_g ~ druh,
    data = data_tucnaci
  )

# Koeficienty stále čteme vzhledem k referenčnímu druhu Adélie
coef(mod_tri_druhy)
```

```
(Intercept)  druhChinstrap  druhGentoo
3700.66225    32.42598      1375.35401
```

```
confint(mod_tri_druhy)
```

```
                2.5 %    97.5 %
(Intercept)  3626.6655 3774.6590
druhChinstrap -100.3686  165.2206
druhGentoo    1264.9117 1485.7963
```

11.1 Tři skupiny potřebují dva přepínače

Adélie zůstává referencí. Model proto vytvoří přepínač pro Chinstrap a druhý pro Gentoo.

Druh	je Chinstrap?	je Gentoo?	Odhadnutá hmotnost
tučňák kroužkový (Adélie)	0	0	β_0
tučňák uzdičkový (Chinstrap)	1	0	$\beta_0 + \beta_1$
tučňák oslí (Gentoo)	0	1	$\beta_0 + \beta_2$

Slovy:

odhadnutá hmotnost těla = průměr Adélie
 + rozdíl Chinstrap vůči Adélie · „je Chinstrap?“
 + rozdíl Gentoo vůči Adélie · „je Gentoo?“ .

Po dosazení skutečných koeficientů a obou přepínačů z tabulky skončí každý řádek právě na průměru daného druhu:

$$\begin{aligned}\widehat{\text{hmotnost}}_{\text{Adélie}} &= 3\,700,7 + 32,4 \cdot 0 + 1\,375,4 \cdot 0 = 3\,700,7 \text{ g}, \\ \widehat{\text{hmotnost}}_{\text{Chinstrap}} &= 3\,700,7 + 32,4 \cdot 1 + 1\,375,4 \cdot 0 = 3\,733,1 \text{ g}, \\ \widehat{\text{hmotnost}}_{\text{Gentoo}} &= 3\,700,7 + 32,4 \cdot 0 + 1\,375,4 \cdot 1 = 5\,076,0 \text{ g}.\end{aligned}$$

Obecně: symbol $x_{\text{Chinstrap},i}$ je číselná odpověď na otázku „je pozorování i Chinstrap?“ a $x_{\text{Gentoo},i}$ na otázku „je pozorování i Gentoo?“. Oba nabývají hodnoty 0 nebo 1. Koeficient $\hat{\beta}_0$ je odhadnutý průměr Adélie, $\hat{\beta}_1$ rozdíl Chinstrap minus Adélie a $\hat{\beta}_2$ rozdíl Gentoo minus Adélie:

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_{\text{Chinstrap},i} + \hat{\beta}_2 x_{\text{Gentoo},i}.$$

Řádek výstupu	Odhad (g)	Význam při referenci Adélie
(Intercept)	3700,7	průměr Adélie
druhChinstrap	32,4	Chinstrap minus Adélie
druhGentoo	1375,4	Gentoo minus Adélie

Koeficienty neobsahují všechny dvojice

Tabulka s referencí Adélie přímo odpovídá na otázky Chinstrap minus Adélie a Gentoo minus Adélie. Rozdíl Gentoo minus Chinstrap v ní není samostatný řádek, i když jej lze ze stejného modelu odvodit.

12 Popisuje model data rozumně?

Než třískupinový model použijeme k testům, zkontrolujeme stejně jako u přímky diagnostiku modelu. U kategoriálního prediktoru má graf residuí proti odhadnutým hodnotám zvláštní, ale očekávaný tvar: model odhaduje jen tři skupinové průměry, takže body tvoří svislé pásy, jeden pro každý druh. Průměry Adélie a Chinstrap se liší jen o 32 g, proto jejich pásy na vodorovné ose téměř splývají a v grafu vidíme zdánlivě jen dva.

Co od diagnostiky potřebujeme


Test předpokládá nezávislá pozorování, přibližně srovnatelnou variabilitu residuí ve skupinách a přibližně normální tvar residuí. Graf residuí proti odhadnutým hodnotám pomáhá posoudit srovnatelnost rozptylu; Q-Q graf pomáhá posoudit tvar rozdělení. Nezávislost však z těchto grafů nepoznáme — musíme ji zdůvodnit způsobem, jakým byla pozorování získána.

Doplňující: co když se skupiny liší variabilitou?

Rozdílný rozptyl residuí neznamená, že rozdíl průměrů zmizel. Znamená, že běžný model se společným residuálním rozptylem nemusí správně vyjádřit nejistotu tohoto rozdílu. Nápově-

dou může být výrazně širší pás residuí u jednoho druhu nebo skupinové rozdělení s velmi odlišnou šířkou.

Pro dvě skupiny už jsme viděli Welchův t-test, který společný rozptyl nevyžaduje. Pro více skupin existuje Welchova ANOVA a v modelovém rámci také další způsoby výpočtu odolnější nejistoty. Volba řešení závisí na otázce, velikosti skupin a tvaru dat; diagnostický graf proto nemá sloužit jako automatický příkaz k transformaci nebo mazání pozorování.



Obrázek 17: Residua proti odhadnutým hodnotám. Svislé pásy odpovídají skupinovým průměrům a jsou vlastností tohoto modelu, ne samy o sobě závadou. Pásy Adélie a Chinstrap téměř splývají, protože jejich průměry jsou skoro stejné.

Ve všech pásích jsou residua rozptýlena kolem nuly. Rozsah není dokonale totožný, ale žádná skupina nevytváří dramaticky odlišný vějíř a žádný jednotlivý bod zjevně neurčuje celý výsledek.

Stejně dva grafy nakreslíte v základním R. Graf residuí proti odhadnutým hodnotám vznikne funkcí `plot()`, vodorovnou čáru v nule přidá `abline()`. Q–Q graf nakreslí `qqnorm()` a referenční přímkou `qqline()`. Na rozdíl od grafů výše nebudou body obarvené podle druhu.

```
# Residua proti hodnotám odhadnutým modelem
plot(
  x = fitted(object = mod_tri_druhy),
  y = resid(object = mod_tri_druhy),
  xlab = "Odhadnutá hmotnost (g)",
```


```

    ylab = "Residuum (g)"
  )

  # Přerušovaná čára v nule
  abline(h = 0, lty = 2)

  # Q-Q graf residuí s referenční přímkou
  qqnorm(y = resid(object = mod_tri_druhy))
  qqline(y = resid(object = mod_tri_druhy))

```



Obrázek 18: Q–Q graf residuí. Body převážně sledují referenční přímkou; menší odchylky na koncích jsou u reálných dat běžné.

Q–Q graf porovnává seřazená residua s hodnotami očekávanými při přibližně normálním tvaru. Body většinou sledují přímkou. Model proto pro srovnání skupin nevykazuje problém, který by převzal hlavní biologický příběh, a můžeme jej použít k testům. To neznamená, že jsou předpoklady „dokázané“; znamená to, že grafy neukazují zásadní rozpor.

13 Jedna celková otázka: analýza rozptylu

U dvou skupin stačil jediný koeficient: Gentoo minus Adélie. U tří skupin už model obsahuje dva rozdílové koeficienty a jejich samostatné řádky neodpovídají přímo na jednu společnou otázku. Celková otázka zní, zda přidání proměnné `druh` zlepší popis dat jako celek:

H_0 : všechny tři průměrné hmotnosti jsou stejné .

Alternativa neříká, která dvojice se liší. Říká pouze, že alespoň jeden průměr není stejný jako ostatní.

13.1 Jeden společný průměr proti třem skupinovým průměrům

Nulová hypotéza odpovídá jednoduššímu modelu bez prediktoru: všem tučňákům přiřadí jeden společný průměr. Model s druhem je složitější a přiřadí každému jedinci průměr jeho druhu. Otázku analýzy rozptylu proto můžeme přeformulovat: **zkrátí tři skupinové průměry residua natolik, aby přidaná složitost modelu stála za to?**



Obrázek 19: Stejná pozorování popsána jedním společným průměrem a třemi skupinovými průměry. Body jsou kvůli překryvu mírně posunuty do stran. Tečkované svislice jsou všechna residua; šipky v levém panelu ukazují posun od společného průměru k průměrům druhů.


V levém panelu jsou residua vzdálenosti od jednoho společného průměru. V pravém panelu jsou vzdálenosti od průměru vlastního druhu. Součet čtverců residuí klesne z 219 307 697 na 72 443 483 g². Rozdílné skupinové průměry tedy vysvětlí část variability, která v jednodušším modelu zůstávala v residuích.

Proč residua umocňujeme? Kdybychom pouze sečetli kladné a záporné vzdálenosti od průměru, navzájem by se vyrušily. Čtverce jsou vždy nezáporné a velkým odchylkám dávají větší váhu. Stejnou myšlenku součtu čtverců residuí už známe z fitování přímky.

Pokles součtu čtverců můžeme zobrazit jako rozdělení původní chyby jednoduššího modelu na dvě části:

$$\underbrace{\text{SSE jednoho průměru}}_{219\,307\,697} = \underbrace{\text{SS zachycený druhem}}_{146\,864\,214} + \underbrace{\text{SSE tří průměrů}}_{72\,443\,483}.$$

Obecně: $\text{SSE}_{\text{jeden průměr}} = \text{SS}_{\text{druh}} + \text{SSE}_{\text{tři průměry}}$, kde SSE je součet čtverců residuí daného modelu a SS_{druh} část, kterou zachytily rozdíly průměrů druhů.



Obrázek 20: Původní součet čtverců residuí se po přidání druhu rozdělí na část zachycenou rozdíly skupinových průměrů a část, která stále zůstává uvnitř druhů.

13.2 Co porovnává F-statistika

Samotný pokles součtu čtverců nestačí. Složitější model téměř vždy residua alespoň trochu zkrátí, protože dostal více koeficientů. Potřebujeme proto porovnat dvě veličiny na férovém měřítku:

1. kolik variability zachytil každý přidaný rozdíl mezi skupinami;
2. jak velký čtverec residua typicky zůstává uvnitř skupin.

F-statistika je poměr právě těchto dvou množství. Protože porovnává dvě variability, jmenuje se metoda **analýza rozptylu**, i když biologická otázka mluví o průměrech.

Slovy:

$$\text{F-statistika} = \frac{\text{variabilita připadající na rozdíly mezi skupinami}}{\text{residuální variabilita uvnitř skupin}}.$$

Čísla už jsme viděli ve dvou konkrétních grafech. V grafu **jeden společný průměr proti třem skupinovým průměrům** byl součet čtverců residuí jednoho průměru 219 307 697 g² a součet čtverců residuí tří průměrů 72 443 483 g². Jejich rozdíl 146 864 214 g² tvoří fialovou část grafu rozkladu součtu čtverců – část zachycenou druhem.

Součty čtverců převedeme na srovnatelné **průměrné čtverce** dělením příslušnými stupni volnosti. Model přidal 2 rozdílové koeficienty; uvnitř skupin zbývá 339 residuálních stupňů volnosti:

$$\text{průměrný čtverec mezi skupinami} = \frac{219\,307\,697 - 72\,443\,483}{2} = \frac{146\,864\,214}{2} = 73\,432\,107,$$

$$\text{průměrný čtverec uvnitř skupin} = \frac{72\,443\,483}{339} = 213\,698.$$

Kdyby druh nepomáhal, zlepšení připadající na jeden nový koeficient by bylo podobně velké jako běžný čtverec residua a F by bylo kolem 1. Čím je čitatel větší vůči jmenovateli, tím více skupinové rozdíly vyčnívají nad variabilitu jedinců uvnitř skupin. V našich datech jejich poměr dává:

$$F = \frac{73\,432\,107}{213\,698} = 343,63 .$$

Obecně:

$$F = \frac{MS_{\text{mezi skupinami}}}{MS_{\text{uvnitř skupin}}}.$$

Symbol MS označuje průměrný čtverec (*mean square*): součet čtverců dělený příslušnými stupni volnosti. F-statistika tak spojuje všechny předchozí kroky: rozdíly průměrů mění odhadnuté hodnoty, tím zkracují residua, z residuí počítáme součty čtverců a jejich férově přepočtený poměr testuje společnou nulovou hypotézu.

```
# Položíme celkovou otázku stejnému třískupinovému modelu
anova(mod_tri_druhy)
```

Analysis of Variance Table

Response: hmotnost_tela_g

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
druh	2	146864214	73432107	343.63	< 2.2e-16 ***
Residuals	339	72443483	213698		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

13.3 Jak číst tabulku `anova()` řádek po řádku

Tabulka je kompaktní, ale každý údaj odpovídá kroku, který jsme už viděli v rovnici nebo grafu:

1. **Řádek druh** popisuje část variability zachycenou přidáním tří skupinových průměrů místo jednoho společného průměru. **Řádek Residuals** popisuje variabilitu, která zůstává kolem skupinových průměrů.
2. **Df pro druh je 2**. Tři skupinové průměry vyjádříme jedním referenčním průměrem a dvěma rozdíly, takže druh přidává $3 - 1 = 2$ stupně volnosti. **Df pro residua je 339**. Máme 342 pozorování a odhadujeme tři skupinové průměry, proto zbývá $342 - 3 = 339$ residuálních stupňů volnosti.
3. **Sum Sq pro druh je 146 864 214 g²**. Je to přesně rozdíl mezi SSE jednoho a tří průměrů a fialová část předchozího rozkladového grafu. **Sum Sq pro Residuals je 72 443 483 g²**, tedy šedá část, která zůstává uvnitř druhů.
4. **Mean Sq** vznikne vydělením každého Sum Sq jeho Df: $73\,432\,107\text{ g}^2$ mezi skupinami a $213\,698\text{ g}^2$ uvnitř skupin.
5. **F value je 343,63**. Je to poměr těchto dvou průměrných čtverců. Hodnota mnohem větší než 1 znamená, že rozdíly skupinových průměrů jsou velké vůči běžné variabilitě jedinců kolem těchto průměrů.
6. **Pr(>F) je p-hodnota**. Nejde o další nezávislý výpočet z dat; vzniká umístěním pozorovaného F do nulového F -rozdělení s 2 stupni volnosti pro čitatele a 339 pro jmenovatele.

13.4 Jak se z F-statistiky stane p-hodnota

Pokud by všechny tři populační průměry byly stejné a platily předpoklady modelu, opakované výběry by vytvářely hodnoty z F -rozdělení $F(2, 339)$. P-hodnota je plocha napravo od naší pozorované hodnoty 343,63:


$$p = (F_{2,339} \geq 343,63 \mid H_0).$$

```
# F a stupně volnosti vezmeme z tabulky anova()
tabulka_anova <- anova(object = mod_tri_druhy)
f_druh <- tabulka_anova["druh", "F value"]
df_druh <- tabulka_anova["druh", "Df"]
df_residua <- tabulka_anova["Residuals", "Df"]

# Plocha F-rozdělení napravo od pozorovaného F
pf(
  q = f_druh,
  df1 = df_druh,
  df2 = df_residua,
  lower.tail = FALSE
)
```

[1] 2.892368e-82

Argument `lower.tail = FALSE` říká R, že chceme pravý chvost: pravděpodobnost hodnot stejně velkých nebo větších než pozorované F . U našeho modelu je tato plocha tak malá, že ji v grafu prakticky neuvidíme.



Obrázek 21: F-rozdělení očekávané při nulové hypotéze. Levý panel ukazuje běžné hodnoty blízko jedné; pravý panel umísťuje pozorovanou F-statistiku na skutečnou osu. P-hodnota je plocha napravo od oranžové čáry a je zde příliš malá, aby byla viditelná.

Pro tučňáky tedy vychází $F(2, 339) = 343,63$ a p-hodnota je $< 0,001$. Za předpokladů modelu jsou data velmi obtížně slučitelná s hypotézou, že všechny tři druhy mají stejnou průměrnou hmotnost.

Celkový výsledek neříká, že se liší každá dvojice

Malá p-hodnota analýzy rozptylu podporuje tvrzení, že alespoň jeden průměr se liší. Neurčuje však, které dvojice se liší, ani zda jsou všechny rozdíly biologicky důležité.

14 Post-hoc: které dvojice se liší?

F-test odpověděl na celkovou otázku: data jsou obtížně slučitelná s hypotézou tří stejných průměrů. Neříká ale, které druhy se liší. Na to se ptají navazující otázky o konkrétních dvojicích. U tří druhů existují tři páry: Chinstrap minus Adélie, Gentoo minus Adélie a Gentoo minus Chinstrap.

Kdybychom každý pár testovali jako izolovanou novou studii, s rostoucím počtem testů by rostla šance na alespoň jeden náhodně extrémní výsledek. Tukeyho post-hoc metoda proto vyhodnotí celou rodinu párových otázek společně. Získáme simultánní intervaly a p-hodnoty upravené pro všechna tři porovnání.

Dvě různé otázky položené stejnému modelu

- **Celkový F-test** se ptá, zda jsou **všechny skupinové průměry stejné**. Odpovídá jedním číslem pro všechny skupiny.
- **Post-hoc porovnání** se ptají, **které konkrétní dvojice** se liší a o kolik gramů. Tukeyho úprava sama zohlední, že se díváme na více dvojic současně, a nepotřebuje proto předchozí „významný“ F-test jako vstupenku.

Párová porovnání dávají smysl, když máme **tři a více skupin** a biologická otázka se týká konkrétních dvojic. U dvou skupin je jediná dvojice a odpověď už dává koeficient modelu. Když jsou párové rozdíly malé a jejich intervaly obsahují nulu, poctivý závěr zní, že data rozdíly neodlišují od nuly. Problémem by bylo vybrat si dodatečně jednu „zajímavou“ dvojici a uvést její neupravenou p-hodnotu, jako by šlo o jedinou předem položenou otázku.

Doplňující: proč jsou Tukeyho intervaly širší

Obyčejný pětadevadesátiprocentní interval chrání dlouhodobé pokrytí jedné předem vybrané veličiny. Zde ale chceme současně číst tři rozdíly. Kdyby měl každý neopravený interval pětiprocentní riziko minutí, šance, že alespoň jeden z celé sady mine svou skutečnou hodnotu, by byla větší než pět procent.

Tukeyho metoda proto nastaví jednotlivé intervaly opatrněji tak, aby přibližně devadesát pět procent opakovaných **celých sad tří intervalů** pokrylo všechny tři skutečné rozdíly současně. Za tuto společnou ochranu obvykle platíme širšími intervaly a většími upravenými p-hodnotami než při izolovaném čtení jediné dvojice.

Doplňující: plánované kontrasty a post-hoc porovnání nejsou stejná otázka

V této lekci klademe celkovou otázku a k ní systematicky prohlížíme všechny tři dvojice. To je post-hoc postup. Výzkumník však někdy ještě před sběrem dat určí jeden biologicky motivovaný kontrast, například „potápěčský druh proti průměru dvou pobřežních druhů“. Taková otázka není dodatečným hledáním nejzajímavější dvojice.

Předem plánovaný kontrast může být věcně přesnější než všechna párová srovnání a stejně jako Tukeyho porovnání nemusí čekat na výsledek celkového F-testu. Stále však musíme transparentně uvést všechny plánované otázky a při více kontrastech zvážit jejich společnou chybovost. Výpočet kontrastů patří do pokročilejší práce s modely.

Funkce `emmeans()` pochází z balíčku `emmeans`; pokud jej nemáte, nainstalujte jej jednou příkazem `install.packages("emmeans")` v Console. Pracuje přímo s již fitovaným objektem `mod_tri_druhy`. **Nefitujeme nový model**. Pouze z téhož lineárního modelu získáme průměrnou hmotnost odhadnutou pro každý druh. V tomto jednoduchém modelu s jediným kategoriálním prediktorem jsou tyto hodnoty stejné jako skupinové průměry, které už známe z grafu.

```
# Ze stejného modelu získáme odhadnutý průměr každého druhu
prumery_druhu <-
  emmeans::emmeans(
    object = mod_tri_druhy,
    specs = ~ druh
  )

prumery_druhu
```

druh	emmean	SE	df	lower.CL	upper.CL
Adelie	3701	37.6	339	3627	3775
Chinstrap	3733	56.1	339	3623	3843
Gentoo	5076	41.7	339	4994	5158

Confidence level used: 0.95

Výstup objektu `prumery_druhu` ukazuje všechny tři průměry odhadnuté modelem. Sloupec `emmean` obsahuje průměrnou hmotnost: 3 700,7 g pro Adélie, 3 733,1 g pro Chinstrap a 5 076,0 g pro Gentoo. Sloupec `SE` je standardní chyba každého průměru, `df` udává residuální stupně volnosti a `lower.CL` s `upper.CL` vymezují 95% interval pro každý skupinový průměr zvlášť.

Tyto intervaly popisují nejistotu jednotlivých průměrů; samy ještě nejsou intervaly jejich vzájemných rozdílů. Ty vzniknou až porovnáním odhadnutých průměrů mezi sebou. Metoda `revpairwise` zachová směr, který jsme používali v grafech: Chinstrap minus Adélie, Gentoo minus Adélie a Gentoo minus Chinstrap. Argument `adjust = "tukey"` říká, že intervaly a p-hodnoty mají zohlednit celou rodinu tří porovnání.

```
# Ze stejných odhadnutých průměrů vytvoříme tři párové rozdíly
post_hoc_druhy <-
  emmeans::contrast(
    object = prumery_druhu,
    method = "revpairwise",
    adjust = "tukey"
  )

summary(
  object = post_hoc_druhy,
  # První TRUE zobrazí intervaly, druhé t-testy a p-hodnoty
  infer = c(TRUE, TRUE)
)
```

```
contrast      estimate    SE  df lower.CL upper.CL t.ratio p.value
Chinstrap - Adelie      32.4 67.5 339     -127      191    0.480 0.8807
Gentoo - Adelie      1375.4 56.1 339     1243     1508   24.495 <0.0001
Gentoo - Chinstrap    1342.9 69.9 339     1178     1507   19.224 <0.0001
```

Confidence level used: 0.95


Conf-level adjustment: tukey method for comparing a family of 3 estimates

P value adjustment: tukey method for comparing a family of 3 estimates

Ve výstupu sledujeme řádky jednotlivých dvojic. Sloupec *estimate* je odhadnutý rozdíl průměrů, *lower.CL* a *upper.CL* jsou meze simultánního intervalu a *p.value* je p-hodnota upravená pro společnou rodinu porovnání. Poznámky pod výstupem potvrzují, že Tukeyho korekce byla použita pro intervaly i p-hodnoty. Přehledněji si stejné hodnoty uspořádáme do tabulky.

Porovnání	Rozdíl (g)	Dolní mez (g)	Horní mez (g)	Upravená p-hodnota
Chinstrap minus Adélie	32,4	-126,5	191,4	0,881
Gentoo minus Adélie	1375,4	1243,2	1507,5	< 0,001
Gentoo minus Chinstrap	1342,9	1178,5	1507,4	< 0,001

Tabulka zachovává hlavní čísla z výstupu `summary(post_hoc_druhy)`. Graf je ukazuje na jedné ose: bod ukáže odhad rozdílu, vodorovná úsečka jeho simultánní interval a svislá čára nulu.



Obrázek 22: Tři Tukeyho post-hoc rozdíly a simultánní 95% intervaly. Nula znamená stejné průměry dané dvojice.

Rozdíl Chinstrap minus Adélie je 32,4 g a simultánní interval od -126,5 do 191,4 g protíná nulu. Data tedy tento malý rozdíl neodlišují od nuly. Oba rozdíly zahrnující Gentoo jsou přibližně 1 343 až 1 375 g a jejich intervaly leží celé nad nulou.

Celková a párová otázka dávají různé informace

Analýza rozptylu ukázala, že všechny tři průměry nejsou stejné. Párová porovnání upřesnila proč: Gentoo se zřetelně liší od obou dalších druhů, zatímco Adélie a Chinstrap mají v tomto výběru velmi podobné průměrné hmotnosti.


15 Co jednoduchý model neoddělil

Rozdíly mezi druhy jsou v těchto datech **asociace**. Jedinci nebyli náhodně přiřazeni ke druhům a druhy nebyly na ostrovech zastoupeny stejně.

Druh	Biscoe	Dream	Torgersen
tučňák kroužkový (Adélie)	44	56	51
tučňák uzdičkový (Chinstrap)	0	68	0
tučňák oslí (Gentoo)	123	0	0

Všichni tučňáci uzdičkoví v tomto výběru pocházejí z ostrova Dream a všichni tučňáci oslí z ostrova Biscoe. Adélie byli měřeni na všech třech ostrovech. Jednoduchý model proto neumí oddělit druh od prostředí ostrova.

Pohlaví také souvisí s hmotností. Následující graf tuto strukturu pouze zviditelňuje; stále nefitujeme model s více prediktory.



Obrázek 23: Hmotnosti tří druhů rozlišené podle zaznamenaného pohlaví. Šedé body mají pohlaví nezaznamenané.

16 Co tedy můžeme říct o tučňácích?

Správný závěr nezačíná p-hodnotou. Jeho jádrem je velikost rozdílů v gramech a jejich nejistota; testová informace a omezení studie je doplňují.

Sestavte závěr z pěti částí

Napište krátký odstavec v pořadí: biologická otázka → rozdíly v gramech → intervaly → celkový a párový test → omezení zobecnění a kauzality.

Příklad opatrného závěru

Ptali jsme se, zda se liší průměrná hmotnost tří druhů tučňáků. V souboru 342 dospělých tučňáků z Palmerova souostroví byli tučňáci oslí (Gentoo) v průměru přibližně o 1 375 g těžší než tučňáci kroužkoví (Adélie) a o 1 343 g těžší než tučňáci uzdičkoví (Chinstrap); simultánní 95% intervaly obou rozdílů ležely celé nad nulou (od 1 243 do 1 508 g a od 1 178 do 1 507 g). Průměry Adélie a Chinstrap se lišily jen o 32 g a jejich interval od -127 do 191 g zahrnoval nulu, takže data tento malý rozdíl neodlišují od nuly. Celková analýza rozptylu

byla s hypotézou tří stejných průměrů obtížně sluchitelná ($F(2, 339) = 343,63$; p -hodnota $< 0,001$). Jde o observační data: druh je v souboru propojený s ostrovem a hmotnost souvisí také s pohlavím, proto rozdíly nelze vykládat jako přímý účinek druhu a závěr platí pro sledované kolonie.

17 Co bude následovat dál

Model s jediným kategoriálním prediktorem odpovídá na jednu otázku: jak se liší průměry druhů. Neumí ale oddělit druh od ostrova nebo pohlaví. Změnil by se odhad rozdílu mezi druhy, kdybychom porovnávali jedince stejného pohlaví nebo současně zohlednili ostrov? Na to potřebujeme model s více prediktory, kterým se zabývá následující lekce.

18 Shrnutí

- Kategoriální prediktor nemění lineární model v úplně jinou metodu; mění způsob, jakým model vytváří odhadnuté hodnoty.
- Ve dvouskupinovém modelu je intercept průměr referenční skupiny a druhý koeficient rozdíl druhé skupiny vůči referenci.
- Odhadnuté hodnoty jsou skupinové průměry a residua jsou vzdálenosti jednotlivých pozorování od jejich skupinového průměru.
- Dvouvýběrový t -test se společným rozptylem je test koeficientu dvouskupinového lineárního modelu.
- Rozdíl mezi průměry posuzujeme vzhledem k variabilitě uvnitř skupin. Na tomto porovnání stojí analýza rozptylu: celkový F -test říká, zda jsou všechny průměry sluchitelné se stejnou hodnotou, ale ne, která dvojice se liší.
- Post-hoc porovnání odpovídají na navazující otázky o konkrétních dvojicích a s Tukeyho úpravou zohledňují, že zkoumáme více dvojic současně.
- Biologický závěr začíná rozdíly v gramech a jejich nejistotou a končí předpoklady a omezeními studie.

18.1 Jak lekce navazuje na předchozí

Dřívější myšlenka	Jak se objevila v této lekci
Typ proměnné určuje vhodný popis	Numerickou hmotnost jsme vysvětlovali kategoriálním druhem.
Graf předchází modelu	Jednotlivci, překryv a variabilita byli vidět dříve než průměry a koeficienty.
$y_i = \hat{y}_i + e_i$	Odhadnuté hodnoty se změnily z bodů na přímce na skupinové průměry; residua zůstala vzdálenostmi od odhadu.

Dřívější myšlenka	Jak se objevila v této lekci
Efekt a jeho nejistota jsou dvě informace	Rozdíly v gramech jsme doplnili intervaly spolehlivosti.
Test je otázka o parametru	Dvouvýběrový t-test se stal testem koeficientu a analýza rozptylu celkovou otázkou o všech skupinových průměrech.
Závěr není jen p-hodnota	Výsledek spojil velikost rozdílů, intervaly, testy, diagnostiku a omezení studie.

18.2 Závěrečná otázka

Co potřebujete vědět, než napíšete „druh určuje hmotnost tučňáka“?

Představte si, že vám někdo ukáže jen tuto větu a malou p-hodnotu analýzy rozptylu. Jaké tři otázky mu položíte?

Možná odpověď

O kolik gramů se druhy liší a jak široké jsou intervaly těchto rozdílů? Které konkrétní dvojice se liší, a které ne (Adélie a Chinstrap jsou si velmi podobné)? Sedí model k datům, tedy jak vypadají residua? A je možné rozdíl připsat druhu, když jsou druhy v souboru propojené s ostrovy a hmotnost souvisí i s pohlavím? Slovo „určuje“ navíc naznačuje příčinu, kterou observační data sama neprokážou.

Slovníček pojmů

Pojmy použité v těchto materiálech a jejich definice. Úplný průběžně aktualizovaný slovníček je dostupný také [online](#).

Interaktivní slovníček je dostupný online: <https://cuni-natur-biostatistics.github.io/slovník/>