

Když prediktor není číslo


Od dvou průměrů k analýze rozptylu

Biostatistika

 Ondřej Mottl

Moodle

Liší se průměrná hmotnost mezi druhy tučňáků?



BIOLOGICKÁ OTÁZKA

Je rozdíl mezi druhy větší, než bychom čekali od variability jednotlivých tučňáků?

Výsledky učení

Po dnešní lekci dokážete:

- fitovat `lm(y ~ skupina)` pro dvě i více skupin;
- interpretovat **intercept jako průměr reference** a další koeficienty jako rozdíly vůči ní;
- vysvětlit t-test a ANOVA jako otázky položené lineárnímu modelu;
- rozlišit **celkový F-test** od **post-hoc porovnání**;
- formulovat závěr v biologicky smysluplných jednotkách.

Co víme z minulé lekce?

$$\text{pozorování} = \text{model} + \text{reziduum}$$


Odhadneme koeficient.

Změříme jeho nejistotu.

Otestujeme nulovou hypotézu.


Logika modelu zůstává stejná. Mění se typ prediktoru.

Podíváme se na data



Co by mohlo vytvářet tak široký rozsah hodnot?

Barva odkryje skupiny



Vidíme rozdíly mezi skupinami i variabilitu uvnitř skupin.

Co by předpovídala nulová hypotéza?

HLASOVÁNÍ

Kdyby druh s hmotností nesouvisel, jaký vzorec bychom čekali?

A

Stejný průměr, žádná variabilita.


B

Stejný průměr, variabilita zůstává.

C

Jiný průměr pro každý druh.


Průměr neříká celý příběh



Rozdíl průměrů hodnotíme vůči rozptylu jednotlivých pozorování.

Rozdíl mezi dvěma skupinami

Dvě vzdálenosti na jedné kře




uvnitř skupin: jak daleko jsou jedinci od vlastního průměru

mezi skupinami: jak daleko jsou skupinové průměry

Stejný rozdíl průměrů, jiný vnitřní rozptyl

ODHAD BEZ POČÍTÁNÍ

Rozdíl průměrů je vždy **1 000 g**. Ve kterém panelu máme největší šanci zamítnout nulovou hypotézu?



Lineární model

Jak jsme minule zapisovali číselný prediktor?

odhadnutá hodnota $(\hat{y}_i)$ = intercept $(\hat{\beta}_0)$
+ sklon $(\hat{\beta}_1) \times$ číselný prediktor (x_i)

KDYŽ $x = 0$

$$\hat{y} = \hat{\beta}_0$$

KDYŽ $x = 1$

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1$$

Co když 0 a 1 nejsou spojitá čísla, ale “přepínač” (vypnout / zapnout)?

Jak dostaneme druh do rovnice?

DISKUZE VE DVOJICI — 90 SEKUND

Jak by se dal “přepínač” (0/1) nastavit aby vybral mezi dvěma druhy?

Druh	Přepínač „je Gentoo?”
Adélie	0
Gentoo	1

Přepínač vybírá mezi dvěma průměry

odhadnutá hmotnost = průměr Adélie
+ přepínač "Je Gentoo?"
× rozdíl Gentoo minus Adélie

Nula rozdíl vypne. Jednička ho zapne.

Nula nechá průměr Adélie, jednička přičte rozdíl

odhadnutá hmotnost = průměr Adélie
+ přepínač "Je Gentoo?"
× rozdíl Gentoo minus Adélie

Průměr Adélie: 3 701 g

Průměr Gentoo: 5 076 g

Rozdíl Gentoo – Adélie: 1 375 g

PŘEPÍNAČ 1 (JE GENTOO)

$$3701 \text{ g} + 1 \times 1375 \text{ g} = 5076 \text{ g}$$

PŘEPÍNAČ 0 (NENÍ GENTOO (ADÉLIE))

$$3701 \text{ g} + 0 \times 1375 \text{ g} = 3701 \text{ g}$$


Jedna rovnice popíše oba druhy

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$$

Symbol	Význam v našich datech
$\hat{y}_i$	odhadnutá hmotnost tučňáka i
$\hat{\beta}_0$	průměr referenčního druhu Adélie
$\hat{\beta}_1$	rozdíl Gentoo minus Adélie
x_i	přepínač: 0 pro Adélie, 1 pro Gentoo

Stejná rovnice jako pro číselný prediktor, jen interpretace koeficientů se liší.

Referenční druh



Model zapisuje jednu skupinu (druh) přímo a ostatní jako rozdíly vůči ní.

Která skupina je referenční?

```
1 levels(x = data_penguins_two$druh)
```

```
[1] "Adelie" "Gentoo"
```

PRVNÍ ÚROVEŇ

Adelie je reference.

VÝSLEDEK

R vytvoří koeficient druhGentoo.

Pořadí úrovní faktoru je součástí interpretace modelu.

Fitujeme stejný lineární model

```
1 mod_dva <- lm(  
2   formula = hmotnost_tela_g ~ druh,  
3   data = data_penguins_two  
4 )  
5  
6 coef(object = mod_dva)
```

```
(Intercept)  druhGentoo  
3700.662      1375.354
```

Dva koeficienty

(Intercept)	druhGentoo
3700.662	1375.354

(Intercept)

3 701 g

Průměrná hmotnost druhu **Adélie**.

druhGentoo

+1 375 g

Rozdíl **Gentoo – Adélie**.

Gentoo: 5 076 g = reference + rozdíl.

Reference není „nejdůležitější“ skupina

HLASOVÁNÍ

Změníme referenci z Adélie na Gentoo. Co se musí změnit?

A

Fitované hodnoty.

B

Jména a znaménka
koeficientů.

C

Rezidua.

Reference mění souřadný systém popisu — ne data ani predikce modelu.

U kontrolních studií je reference zásadní

Skupina	Koeficient	Význam
kontrola	$\hat{\beta}_0$	průměr kontroly
lék A	$\hat{\beta}_1$	A – kontrola
lék B	$\hat{\beta}_2$	B – kontrola

Je-li kontrola referencí, každý koeficient odpovídá přirozené otázce „oproti kontrole“.

Ale reference nevytváří kontrolu


POZOR NA INTERPRETACI

Příkaz `relevel()` pouze změní, kterou skupinu model používá jako výchozí. Nevytváří randomizaci, kontrolní podmínky ani kauzální důkaz.

```
1 data_pokus <-  
2   data.frame(  
3     skupina = factor(c("kontrola", "lék A", "lék B"))  
4   )  
5  
6 data_pokus$skupina <-  
7   relevel(  
8     x = data_pokus$skupina,  
9     ref = "kontrola"  
10  )
```


Kontrolní skupinu vytváří design studie. Reference pouze zpřehlední otázku.

Fit modelu




Každý tučňák dostane jako fit průměr svého druhu.

Reziduum je stále vzdálenost od predikce



Jiný tvar prediktoru, stejná definice rezidua.

Jak přesně jsme odhadli rozdíl?



Odhad: **+1 375 g**

95% CI: **1 261 až 1 490 g**

Statistický test (T-test)

nulová hypotéza: průměr Gentoo minus průměr Adélie = 0 g


***t*-STATISTIKA**

Vzdálenost v jednotkách standardní chyby (SE) = rozdíl mezi pozorovaným a nulovým nulovým rozdílem ÷ standardní chyba (SE) odhadu rozdílu.

23,61

Pro dvě skupiny dává tento model stejnou testovou otázku jako klasický dvouvýběrový t-test se společným rozptylem.

Kde leží naše t v nulovém rozdělení?



p -hodnota $< 0,001$ je plocha v obou ocasech ještě dál od nuly než pozorované t .

Výsledek v R

```
1 coef(summary(mod_dva))
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	3700.662	39.02377	94.83098	2.002699e-210
druhGentoo	1375.354	58.24410	23.61362	8.030929e-68

Co můžeme říci biologicky?

VÝSLEDEK

V tomto souboru jsou tučňáci Gentoo v průměru o přibližně **1 375 g těžší** než tučňáci Adélie (95% CI 1 261 až 1 490 g).

Rozsah závěru

Jde o asociaci v pozorovaných datech.

Více skupin

Co se stane, když přidáme třetí druh?

PŘEDPOVĚĎ

Kolik koeficientů potřebujeme pro tři skupinové průměry?

A

Jeden

B


Dva

C

Tři

tři průměry = jeden referenční (intercept) + dva rozdíly .

Tři druhy, tři průměry



Adélie a Chinstrap mají podobné průměry; Gentoo je zřetelně výše.

Tři průměry potřebují dva přepínače

Druh	Referenční průměr Adélie	Je Chinstrap?	Je Gentoo?
Adélie	1	0	0
Chinstrap	1	1	0
Gentoo	1	0	1

Každý řádek říká, které rozdíly se mají přičíst k průměru Adélie.

Tři průměry potřebují dva přepínače

odhadnutá hmotnost = průměr Adélie

+ přepínač Chinstrap $\times$ rozdíl Chinstrap minus Adélie

+ přepínač Gentoo $\times$ rozdíl Gentoo minus Adélie

Každý druh zapne jinou kombinaci

Základ: průměr Adélie = 3 701 g

Rozdíly: Chinstrap – Adélie = 32 g; Gentoo – Adélie = 1 375 g

ADÉLIE

$$3\,701\text{ g} + 0 \times 32\text{ g} + 0 \times 1\,375\text{ g} = \mathbf{3\,701\text{ g}}$$

CHINSTRAP

$$3\,701\text{ g} + 1 \times 32\text{ g} + 0 \times 1\,375\text{ g} = \mathbf{3\,733\text{ g}}$$

GENTOO

$$3\,701\text{ g} + 0 \times 32\text{ g} + 1 \times 1\,375\text{ g} = \mathbf{5\,076\text{ g}}$$

Jedna rovnice popíše všechny tři druhy

odhadnutá hmotnost = průměr Adélie
+ přepínač Chinstrap $\times$ rozdíl Chinstrap minus Adélie
+ přepínač Gentoo $\times$ rozdíl Gentoo minus Adélie

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 I_{\text{Chinstrap},i} + \hat{\beta}_2 I_{\text{Gentoo},i}$$

I je přepínač pro konkrétního tučňáka i . $\hat{\beta}_0$ je průměr Adélie; $\hat{\beta}_1$ a $\hat{\beta}_2$ jsou rozdíly vůči Adélie.

Pro tři skupiny potřebujeme jeden referenční průměr a dva rozdílové přepínače.


Jedna otázka zůstala otevřená

Liší se alespoň jeden skupinový průměr od ostatních?

Nechceme zatím tři samostatné testy. Chceme jednu celkovou otázku.

Porovnáme model s jedním průměrem (nulový) a model se třemi průměry.

Jeden nebo tři?



nulový model: jeden společný průměr

skupinový model: jeden průměr pro každý druh


F-test porovnává rozdíly průměrů s variabilitou uvnitř skupin

Testová statistika porovnává **variabilitu mezi skupinovými průměry** s **variabilitou jedinců uvnitř skupin**.

Čitatel roste, když se vzdalují průměry. Jmenovatel roste, když se více rozptylují jedinci.

Součty čtverců ve třech skupinách


součet uvnitř skupin = čtverce vzdáleností jedinců
od vlastního skupinového průměru



$$\begin{aligned}SS_{\text{Adélie}} &= (-300)^2 + (-100)^2 + 400^2 = 260\,000 \\SS_{\text{Chinstrap}} &= (-400)^2 + 100^2 + 300^2 = 260\,000 \\SS_{\text{Gentoo}} &= (-600)^2 + 200^2 + 400^2 = 560\,000 \\SS_{\text{uvnitř}} &= 260\,000 + 260\,000 + 560\,000 \\&= 1\,080\,000 \text{ g}^2\end{aligned}$$

Skupinové průměry měří rozdíl mezi skupinami


součet mezi skupinami = velikosti skupin $\times$ čtverce vzdáleností
skupinových průměrů od společného průměru



$$3 \times (-700)^2 + 3 \times (100)^2 + 3 \times (600)^2 = 2\,580\,000 \text{ g}^2$$

Celkový součet má dvě viditelné části

celkový součet čtverců = součet mezi skupinami + součet uvnitř skupin



Dělením stupni volnosti získáme průměrné čtverce

$$MS = \frac{SS}{\text{stupně volnosti}}$$

MEZI SKUPINAMI

$$df = 3 - 1 = 2$$

$$MS_{\text{mezi}} = \frac{2\,580\,000}{2} = 1\,290\,000 \text{ g}^2$$

UVNITŘ SKUPIN

$$df = 9 - 3 = 6$$

$$MS_{\text{uvnitř}} = \frac{1\,080\,000}{6} = 180\,000 \text{ g}^2$$

Oba součty čtverců přepočítáme na variabilitu připadající na jeden stupeň volnosti.

Poměr průměrných čtverců je F

$$F = \frac{MS_{\text{mezi}}}{MS_{\text{uvnitř}}} = \frac{1\,290\,000}{180\,000} = 7,17$$

MS_{mezi}

variabilita připadající na jeden stupeň
volnosti mezi skupinami

$MS_{\text{uvnitř}}$

variabilita připadající na jeden stupeň
volnosti uvnitř skupin

Analýza se jmenuje ANOVA

ANOVA = analýza rozptylu


Název zdůrazňuje mechanismus: rozdíly mezi průměry posuzujeme pomocí rozptylu uvnitř skupin.

Model je stále `lm()`. ANOVA je test tohoto modelu.

Stejný vnitřní rozptyl, jiný rozdíl

POŘADÍ PANELŮ

Seřad'te panely od nejslabšího po nejsilnější důkaz proti shodným průměrům.




Test v R

```
1 mod_tri <- lm(  
2   formula = hmotnost_tela_g ~ druh,  
3   data = data_penguins  
4 )  
5  
6 anova(object = mod_tri)
```

Zdroj variability	df	F	p -hodnota
mezi druhy	2	343,6	< 0,001
uvnitř druhů	339	—	—

$F = 343,6$, $p < 0,001$: data odporují shodě všech tří průměrů.

Kde leží naše F v nulovém rozdělení?



p -hodnota je plocha napravo od pozorovaného F ; zde je tak malá, že ji v grafu téměř nevidíme.

Co nám malá p -hodnota říká?

HLASOVÁNÍ

Který závěr plyne přímo z celkového F-testu?

A

Všechny dvojice se liší.

B


Alespoň jeden průměr se liší.

C

Gentoo je příčinou rozdílu.

Celkový test neříká, které konkrétní dvojice se liší.

Stejné F , jiný biologický rozdíl



Všechny panely mají $F = 20$. Jsou biologické závěry stejné?

Síla důkazu není velikost efektu

STEJNÉ

- poměr rozdílu k šumu;
- F -statistika;
- p -hodnota.

JINÉ

- rozdíl v gramech;
- biologická relevance;
- praktický závěr.

Vždy uvádějte odhad efektu a jeho interval — ne pouze p -hodnotu.

Post-hoc test



ANOVA: „je někde rozdíl?“ → post-hoc: „mezi kterými dvojicemi?“

Ze stejného modelu

Post-hoc otázky čteme ze stejného fitovaného modelu. Nefitujeme tři nové modely.

MODEL

`mod_tri`

ODHADNUTÉ PRŮMĚRY

`emmeans()` pro každý druh

3. PÁROVÉ ROZDÍLY

`contrast()` s Tukeyho úpravou

Post-hoc v R

```
1 prumery_emm <-  
2   emmeans::emmeans(  
3     object = mod_tri,  
4     specs = ~druh  
5   )  
6  
7 post_hoc_tri <-  
8   emmeans::contrast(  
9     object = prumery_emm,  
10    method = "revpairwise",  
11    adjust = "tukey"  
12  )
```

`specs` vybírá skupinové průměry; `adjust` říká, že tři navazující otázky hodnotíme společně.


Výsledek post-hoc testu

```
1 summary(post_hoc_tri)
```

contrast	estimate	SE	df	t.ratio	p.value
Chinstrap - Adelie	32.4	67.5	339	0.480	0.8807
Gentoo - Adelie	1375.4	56.1	339	24.495	<0.0001
Gentoo - Chinstrap	1342.9	69.9	339	19.224	<0.0001

P value adjustment: tukey method for comparing a family of 3 estimates

Tři rozdíly na jedné ose



Tukeyho simultánní 95% intervaly: všechna tři porovnání jsou vyhodnocena společně.

Co jsme zjistili?

GENTOO


Je v průměru asi o **1,3 kg těžší** než Adélie i Chinstrap.

ADÉLIE VS. CHINSTRAP

Odhad rozdílu je jen asi **32 g** a interval obsahuje nulu.


Významná (signifikantní) ANOVA neznamená, že se liší každá dvojice.

Diagnostika se neztratila



Vidíme systematický vzorec, extrémní bod nebo výrazně odlišný rozptyl skupin?

Druh není celý příběh



Jednofaktorový model odpovídá jedné otázce. Další proměnné vyžadují bohatší model a opatrnější interpretaci.

Pět věcí, které si odnést

1. Kategoriální prediktor vstupuje do `lm()` pomocí přepínačů 0/1.
2. Intercept je průměr **referenční skupiny**.
3. Ostatní koeficienty jsou rozdíly vůči referenci.
4. ANOVA porovnává variabilitu mezi skupinami s variabilitou uvnitř nich.
5. Po celkovém testu následují post-hoc porovnání, odhad efektu a jeho interval.

U studií s kontrolou zvolte kontrolu jako referenci — a stále odděľujte modelové kódování od designu studie.

Poslední otázka

Když dvě skupiny mají stejný rozdíl průměrů, co rozhoduje o síle důkazu?

Rozdíl musíme číst v kontextu variability uvnitř skupin, velikosti vzorku a designu studie.

Materiály

- Zdrojový repozitář
- Online prezentace
- Moodle

Data: Palmer Station LTER a palmerpenguins. Druhová ilustrace: Allison Horst. Ostatní narativní ilustrace byly vytvořeny pro tuto lekci.