

Když prediktor není číslo


Od dvou průměrů k analýze rozptylu

Biostatistika - L06

 Ondřej Mottl

Moodle

Liší se průměrná hmotnost mezi druhy tučňáků?



BIOLOGICKÁ OTÁZKA

Je rozdíl mezi druhy větší, než bychom čekali od variability jednotlivých tučňáků?

Jeden řádek dat = jeden změřený tučňák.

Ilustrace: Allison Horst · Data: Palmer Station LTER / palmerpenguins

Výsledky učení

Po dnešní lekci dokážete:

- fitovat `lm(y ~ skupina)` pro dvě i více skupin;
- interpretovat **intercept jako průměr reference** a další koeficienty jako rozdíly vůči ní;
- vysvětlit t-test a ANOVA jako otázky položené lineárnímu modelu;
- rozlišit **celkový F-test** od **post-hoc porovnání**;
- formulovat závěr v biologicky smysluplných jednotkách.

Co si neseme z L05?

$$\text{pozorování} = \text{model} + \text{reziduum}$$

1

Odhadneme koeficient.

2


Změříme jeho nejistotu.

3

Položíme nulovou hypotézu.


Dnes se nemění logika modelu. Mění se typ prediktoru.

Zatím skryjme druh



Co by mohlo vytvářet tak široký rozsah hodnot?

Barva odkryje skupiny



Vidíme rozdíly mezi skupinami i variabilitu uvnitř skupin.

Co by předpovídala nulová hypotéza?

HLASOVÁNÍ

Kdyby druh s hmotností nesouvisel, jaký vzorec bychom čekali?

A

Stejný průměr, žádná variabilita.

B


Stejný průměr, variabilita zůstává.

C

Jiný průměr pro každý druh.


Když nehlasujeme: zvolte možnost a obhajte ji sousedovi.

Průměr neříká celý příběh



Rozdíl průměrů hodnotíme vůči rozptylu jednotlivých pozorování.

Dvě vzdálenosti na jedné kře




uvnitř skupin: jak daleko jsou jedinci od vlastního průměru

mezi skupinami: jak daleko jsou skupinové průměry

Stejné průměry, jiný vnitřní rozptyl

ODHAD BEZ POČÍTÁNÍ

Rozdíl průměrů je vždy **1 000 g**. Ve kterém panelu budou data nejsilněji odporovat nulové hypotéze?



Mezera zůstala, důkaz zeslábl

SD 250 G

$$F = 80$$

SD 500 G

$$F = 20$$

SD 1 000 G

$$F = 5$$

Statistická otázka porovnává **variabilitu mezi skupinami** s **variabilitou uvnitř skupin**.

Jak jsme v L05 zapisovali číselný prediktor?

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$$

KDYŽ $x = 0$

$$\hat{y} = \hat{\beta}_0$$

KDYŽ $x = 1$

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1$$

Co když 0 a 1 nejsou dávka, ale přepínač mezi skupinami?

Jak dostaneme druh do rovnice?

DISKUZE VE DVOJICI — 90 SEKUND

Navrhněte číselný zápis pro dvě možnosti:

- Adélie
- Gentoo

$$x_i = \begin{cases} 0 & \text{Adélie} \\ 1 & \text{Gentoo} \end{cases}$$

Nula vypne rozdíl, jednička ho zapne

ADÉLIE: $x = 0$

$$\hat{y} = \hat{\beta}_0$$


referenční průměr

GENTOO: $x = 1$

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1$$

reference + rozdíl

Modelový pas má jednu referenční stránku



Model zapisuje jednu skupinu přímo a ostatní jako rozdíly vůči ní.

Která skupina je referenční?

```
1 levels(data_penguins_two$druh)
```

```
[1] "Adelie" "Gentoo"
```

PRVNÍ ÚROVEŇ

Adelie je reference.

VÝSLEDEK

R vytvoří koeficient druhGentoo.

Pořadí úrovní faktoru je součástí interpretace modelu.

Fitujeme stejný lineární model

```
1 mod_dva <- lm(  
2   hmotnost_tela_g ~ druh,  
3   data = data_penguins_two  
4 )  
5  
6 coef(summary(mod_dva))
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	3700.662	39.02377	94.83098	2.002699e-210
druhGentoo	1375.354	58.24410	23.61362	8.030929e-68

Dva koeficienty, dvě biologické věty

(Intercept)

3 701 g

Průměrná hmotnost druhu **Adélie**.

druhGentoo

+1 375 g

Rozdíl **Gentoo – Adélie**.

Gentoo: 5 076 g = reference + rozdíl.

Reference není „nejdůležitější“ skupina

HLASOVÁNÍ

Změníme referenci z Adélie na Gentoo. Co se musí změnit?

A

Fitované hodnoty.

B

Jména a znaménka
koeficientů.

C

Rezidua.

Reference mění souřadný systém popisu — ne data ani predikce modelu.

U kontrolních studií je reference zásadní

KONTROLA

$\hat{\beta}_0$
průměr kontroly

OŠETŘENÍ A

$\hat{\beta}_1$
A – kontrola

OŠETŘENÍ B

$\hat{\beta}_2$
B – kontrola

Je-li kontrola referencí, každý koeficient odpovídá přirozené otázce „oproti kontrole“.

Ale reference nevytváří kontrolu


POZOR NA INTERPRETACI

Příkaz `relevel()` pouze změní, kterou skupinu model používá jako výchozí. Nevytváří randomizaci, kontrolní podmínky ani kauzální důkaz.

```
1 data_pokus <- data_pokus |>
2   dplyr::mutate(
3     skupina = relevel(skupina, ref = "kontrola")
4   )
```


Kontrolní skupinu vytváří design studie. Reference pouze zpřehlední otázku.

Model vrací skupinové průměry



Každý tučňák dostane jako fit průměr svého druhu.

Reziduum je stále svislá vzdálenost




Jiný tvar prediktoru, stejná definice rezidua.

Jak přesně jsme odhadli rozdíl?

Odhad: **+1 375 g**

95% CI: **1 261 až 1 490 g**



T-test je otázka na jeden koeficient

$$H_0 : \beta_{\text{Gentoo-Adélie}} = 0$$

***t*-STATISTIKA**

23.61

***p*-HODNOTA**

<0.001

Pro dvě skupiny dává tento model stejnou testovou otázku jako klasický dvouvýběrový t-test se společným rozptylem.

Co můžeme říci biologicky?

VÝSLEDEK

V tomto souboru jsou tučňáci Gentoo v průměru o přibližně **1 375 g těžší** než tučňáci Adélie (95% CI 1 261 až 1 490 g).

Rozsah závěru

Jde o asociaci v pozorovaných datech. Samotný model nedokazuje, že druh rozdíl způsobil.

Co se stane, když přidáme třetí druh?

PŘEDPOVĚĎ

Kolik koeficientů potřebujeme pro tři skupinové průměry?

A

Jeden

B


Dva

C

Tři

Jeden intercept + dva rozdíly = tři průměry.

Tři druhy, tři průměry



Adélie a Chinstrap mají podobné průměry; Gentoo je zřetelně výše.

Dva přepínače stačí

Druh	(Intercept)	druhChinstrap	druhGentoo
Adélie	1	0	0
Chinstrap	1	1	0
Gentoo	1	0	1

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 I_{\text{Chinstrap},i} + \hat{\beta}_2 I_{\text{Gentoo},i}$$

Pro k skupin potřebujeme $k - 1$ rozdílových přepínačů a jeden intercept.


Jedna otázka zůstala otevřená

Liší se alespoň jeden skupinový průměr od ostatních?

Nechceme zatím tři samostatné testy. Chceme jednu celkovou otázku.

Porovnáme model s jedním průměrem a model se třemi průměry.


Jeden krmný bod, nebo tři?



nulový model: jeden společný průměr

skupinový model: jeden průměr pro každý druh

O kolik znalost druhu zmenší nevysvětlenou variabilitu?




Znalost druhu odstraní asi 67 % původního součtu čtverců chyb.

Stejný vnitřní rozptyl, jiná mezera

NEJDŘÍV POŘADÍ

Seřadte panely od nejslabšího po nejsilnější důkaz proti shodným průměrům.



Poměr roste se čtvercem mezery

ROZDÍL 250 G

$$F = 1,25$$

ROZDÍL 500 G


$$F = 5$$

ROZDÍL 1 000 G

$$F = 20$$

$$F = \frac{\text{variabilita mezi skupinami}}{\text{variabilita uvnitř skupin}}$$

Stejné F , jiný biologický rozdíl



Všechny panely mají $F = 20$ a stejnou p -hodnotu. Jsou biologické závěry stejné?

Síla důkazu není velikost efektu

STEJNÉ

- poměr rozdílu k šumu;
- F -statistika;
- p -hodnota.

JINÉ

- rozdíl v gramech;
- biologická relevance;
- praktický závěr.

Vždy uvádějte odhad efektu a jeho interval — ne pouze p -hodnotu.

Ted' můžeme pojmenovat celkový test

ANOVA = analýza rozptylu

Název zdůrazňuje mechanismus: rozdíly mezi průměry posuzujeme pomocí rozptylu uvnitř skupin.

Model je stále `lm()`. ANOVA je celková otázka položená tomuto modelu.

Jedna tabulka, jedna celková otázka

```
1 mod_tri <- lm(  
2   hmotnost_tela_g ~ druh,  
3   data = data_penguins  
4 )  
5  
6 anova(mod_tri)
```

Analysis of Variance Table

Response: hmotnost_tela_g

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
druh	2	146864214	73432107	343.63	< 2.2e-16 ***
Residuals	339	72443483	213698		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

$F = 343.6$, $p < 0,001$: data odporují shodě všech tří průměrů.

Co nám malá p -hodnota říká?

HLASOVÁNÍ

Který závěr plyne přímo z celkového F-testu?

A

Všechny dvojice se liší.

B

Alespoň jeden průměr se liší.

C

Gentoo je příčinou rozdílu.


Celkový test neříká, které konkrétní dvojice se liší.

Lupa přichází až po celkovém pohledu



ANOVA: „je někde rozdíl?“ → post-hoc: „mezi kterými dvojicemi?“

Tři dvojice, jedna rodina otázek



Tukeyho simultánní 95% intervaly: všechna tři porovnání jsou vyhodnocena společně.

Co odhalila lupa?

GENTOO


Je v průměru asi o **1,3 kg těžší** než Adélie i Chinstrap.

ADÉLIE VS. CHINSTRAP

Odhad rozdílu je jen asi **32 g** a interval obsahuje nulu.


Významná ANOVA neznamená, že se liší každá dvojice.

Diagnostika se neztratila




Vidíme systematický vzorec, extrémní bod nebo výrazně odlišný rozptyl skupin?

Druh není jediný možný příběh



Jednofaktorový model odpovídá jedné otázce. Další proměnné vyžadují bohatší model a opatrnější interpretaci.

Celý postup na jedné trase



V každém kroku se ptáme: „co je mezi skupinami a co zůstává uvnitř?“

Pět věcí, které si odnést

1. Kategoriální prediktor vstupuje do `lm()` pomocí přepínačů 0/1.
2. Intercept je průměr **referenční skupiny**.
3. Ostatní koeficienty jsou rozdíly vůči referenci.
4. ANOVA porovnává variabilitu mezi skupinami s variabilitou uvnitř nich.
5. Po celkovém testu následují post-hoc porovnání, odhad efektu a jeho interval.

U studií s kontrolou zvolte kontrolu jako referenci — a stále odděľujte modelové kódování od designu studie.

Poslední otázka

Když dvě skupiny mají stejný rozdíl průměrů, co rozhoduje o síle důkazu?

Rozdíl musíme číst v kontextu variability uvnitř skupin, velikosti vzorku a designu studie.

Materiály

- Zdrojový repozitář
- Online prezentace
- Moodle

Data: Palmer Station LTER a palmerpenguins. Druhová ilustrace: Allison Horst. Ostatní narativní ilustrace byly vytvořeny pro tuto lekci.